



UNIVERSITAT
POLITÈCNICA
DE VALÈNCIA



Departamento de Sistemas Informáticos y Computación
Universidad Politécnica de Valencia

Transferencia de modelos MEG de contexto largo a EEG para clasificación de palabras en escucha natural

TRABAJO DE FIN DE MÁSTER

Máster Universitario en Inteligencia Artificial,
Reconocimiento de Formas e Imagen Digital

Autor: Ricardo Díaz Peris

Tutores: Vicent Juan Botti Navarro, Alfons Juan Císcar

Curso 2025-2026

Resum

La descodificació de paraules a partir de senyals cerebrals no invasives presenta importants dificultats degudes al baix nivell de senyal útil, la variabilitat entre subjectes i les diferències entre modalitats com MEG i EEG. En aquest treball s'adapta el model MEG-XL, dissenyat originalment per a l'aprenentatge de representacions de context llarg en MEG, a un escenari d'EEG durant l'escolta natural. L'adaptació se centra a construir un pipeline reproduïble per a avaluar si les representacions apreses en MEG poden transferir-se a EEG en tasques de classificació de paraules. Per això, s'integra l'arquitectura de MEG-XL amb un nou adaptador per a diferents conjunts de dades d'EEG, que transforma els registres d'aquest tipus de sensors i les anotacions d'escolta en segments alineats amb paraules. El pipeline incorpora remostratge, normalització, extracció de finestres temporals per paraula, màscares de sensors i codificació explícita del tipus de sensor EEG. A partir d'aquests segments, el model obté representacions neuronals contextualitzades mitjançant un Transformer amb atenció criss-cross i les compara amb embeddings lingüístics generats per T5 mitjançant una pèrdua contrastiva. L'objectiu principal és analitzar la viabilitat tècnica i experimental de traslladar models de context llarg entrenats en MEG a dades EEG per a començar a investigar una solució tancada de brain-to-text que incloga EEG. Este enfocament permet estudiar les barreres pràctiques de la transferència entre modalitats, identificar els punts crítics del preprocesament i assentar una base per a futurs models multimodals M/EEG aplicats a la descodificació de llenguatge natural.

Paraules clau: Descodificació neuronal; EEG; MEG; aprenentatge per transferència; escolta natural; classificació de paraules; models de context llarg; brain-to-text

Resumen

La decodificación de palabras a partir de señales cerebrales no invasivas presenta importantes dificultades debidas al bajo nivel de señal útil, la variabilidad entre sujetos y las diferencias entre modalidades como MEG y EEG. En este trabajo se adapta el modelo MEG-XL, diseñado originalmente para el aprendizaje de representaciones de contexto largo en MEG, a un escenario de EEG durante escucha natural. La adaptación se centra en construir un pipeline reproducible para evaluar si las representaciones aprendidas en MEG pueden transferirse a EEG en tareas de clasificación de palabras. Para ello, se integra la arquitectura de MEG-XL con un nuevo adaptador diferentes datasets de EEG, que transforma los registros de este tipo de sensores y las anotaciones de escucha en segmentos alineados a palabras. El pipeline incorpora re-muestreo, normalización, extracción de ventanas temporales por palabra, máscaras de sensores y codificación explícita del tipo de sensor EEG. A partir de estos segmentos, el modelo obtiene representaciones neuronales contextualizadas mediante un Transformer con atención criss-cross y las compara con embeddings lingüísticos generados por T5 mediante una pérdida contrastiva. El objetivo principal es analizar la viabilidad técnica y experimental de trasladar modelos de contexto largo entrenados en MEG a datos EEG para comenzar a investigar una solución cerrada de brain-to-text que incluya EEG. Este enfoque permite estudiar las barreras prácticas de la transferencia entre modalidades, identificar los puntos críticos del preprocesamiento y sentar una base para futuros modelos multimodales M/EEG aplicados a decodificación de lenguaje natural.

Palabras clave: Decodificación neuronal; EEG; MEG; aprendizaje por transferencia; escucha natural; clasificación de palabras; modelos de contexto largo; brain-to-text

Abstract

Decoding words from non-invasive brain signals presents significant challenges due to the low level of useful signal, inter-subject variability, and differences between modalities such as MEG and EEG. In this work, the MEG-XL model originally designed for learning long-range context representations in MEG is adapted to an EEG setting during natural listening. The adaptation focuses on building a reproducible pipeline to evaluate whether representations learned in MEG can be transferred to EEG in word classification tasks. To this end, the MEG-XL architecture is integrated with a new adapter for various EEG datasets, which transforms EEG recordings and listening annotations into word-aligned segments. The pipeline incorporates resampling, normalization, word-based temporal window extraction, sensor masking, and explicit encoding of the EEG sensor type. From these segments, the model obtains contextualized neural representations using a Transformer with cross-attention and compares them with linguistic embeddings generated by T5 via a contrastive loss. The main objective is to analyze the technical and experimental feasibility of transferring long-context models trained on MEG data to EEG data in order to begin investigating an end-to-end brain-to-text solution that incorporates EEG. This approach allows us to study the practical barriers to cross-modal transfer, identify critical points in preprocessing, and lay the groundwork for future multimodal M/EEG models applied to natural language decoding.

Key words: Neural decoding; EEG; MEG; transfer learning; natural listening; word classification; long-context models; brain-to-text

Índice general

Índice general	V
Índice de figuras	VII
Índice de tablas	VIII
Índice de acrónimos	IX
1 Introducción	1
1.1 Motivación	1
1.2 Objetivos	1
1.3 Estructura de la memoria	1
2 Marco teórico	3
2.1 Interfaces cerebro-computador	3
2.1.1 Decodificación cerebral del lenguaje	4
2.1.2 Métodos invasivos y no invasivos	5
2.2 Aprendizaje profundo	6
2.2.1 Redes neuronales y Transformers	6
2.2.2 Aprendizaje autosupervisado y transferencia de aprendizaje	7
2.3 Electroencefalografía y magnetoencefalografía	7
2.3.1 Electroencefalografía	8
2.3.2 Magnetoencefalografía	10
2.3.3 Comparación entre EEG y MEG	12
2.4 Procesamiento de señales cerebrales	13
2.4.1 Actividad oscilatoria y bandas de frecuencia	13
2.4.2 Preprocesamiento de EEG y MEG	14
2.4.3 Representación temporal y espacial de las señales	15
2.4.4 Aprendizaje profundo aplicado a EEG y MEG	16
2.5 Decodificación contextual de palabras	17
2.5.1 Representaciones lingüísticas	17
2.5.2 Aprendizaje contrastivo	18
2.5.3 Evaluación de la clasificación de palabras	19
2.6 Estado del arte	20
2.6.1 Decodificación mediante EEG	22
2.6.2 Decodificación mediante MEG	22
2.6.3 Modelos preentrenados de señales cerebrales	23
2.6.4 Limitaciones de los trabajos existentes	23
3 Datasets utilizados	25
3.1 Selección de conjuntos de entrenamiento	26
3.2 Datasets de entrenamiento	26
3.2.1 Datasets de lectura	26
3.2.2 Datasets de escucha	27
3.3 Dataset de fine-tuning	29
3.3.1 OpenNeuro ds004408	29
3.4 Tabla resumen	30

4	Adaptación de MEG-XL a “EEG-XL”	31
4.1	Descripción general de la propuesta	31
4.2	Preprocesamiento del EEG	32
4.2.1	Preprocesado de la señal	32
4.2.2	Alineamiento con las palabras	34
4.3	Adaptación de la arquitectura MEG-XL	35
4.3.1	Componentes conservados	35
4.3.2	Cambios para trabajar con canales EEG	35
4.3.3	Tokenización de la señal	37
4.3.4	Modelado temporal y espacial	37
4.4	Entrenamiento del modelo	38
4.4.1	Preentrenamiento autosupervisado	38
4.4.2	Clasificación contextual de palabras	38
5	Evaluación experimental	41
5.1	Diseño experimental	41
5.2	Particiones de los datos	42
5.2.1	Preentrenamiento autosupervisado	42
5.2.2	Ajuste supervisado sobre OpenNeuro ds004408	42
5.3	Configuración del preentrenamiento	43
5.3.1	Representación de la entrada	43
5.3.2	Objetivo autosupervisado	43
5.3.3	Hiperparámetros	44
5.4	Configuración del ajuste supervisado	45
5.4.1	Proyección al espacio lingüístico	45
5.4.2	Pérdida contrastiva	45
5.4.3	Hiperparámetros	45
5.5	Métricas de evaluación	46
5.5.1	Métricas del preentrenamiento	46
5.5.2	Recuperación de palabras	46
5.6	Resultados	47
5.6.1	Preentrenamiento de lectura y escucha	47
5.6.2	Clasificación contextual de palabras	48
5.6.3	Cobertura de la evaluación	50
5.6.4	Diferencias entre condiciones	50
5.6.5	Comparación con trabajos previos	50
5.6.6	Resumen de los resultados	51
6	Conclusiones y trabajo futuro	53
6.1	Conclusiones	53
6.2	Cumplimiento de los objetivos	53
6.3	Líneas de trabajo futuro	53
	Bibliografía	55
	Apéndices	
A	Configuració del sistema	61
A.1	Fase d’inicialització	61
A.2	Identificació de dispositius	61
B	??? ?????????? ????	63

Índice de figuras

2.1	Etapas generales de una interfaz cerebro-computador. La salida del decodificador puede utilizarse directamente o cerrar el bucle mediante realimentación al usuario.	3
2.2	Principales paradigmas experimentales utilizados en decodificación cerebral del lenguaje. Cada paradigma ofrece un compromiso distinto entre naturalidad, facilidad de alineamiento y presencia de artefactos.	5
2.3	Ejemplos de adquisición invasiva y no invasiva	6
2.4	Esquema conceptual de la observación de una fuente neuronal mediante EEG y MEG.	8
2.5	Ejemplo de gorro EEG	9
2.6	Ejemplo de adquisición mediante MEG	11
2.7	Flujo habitual de preparación de registros EEG y MEG para aprendizaje automático. El orden exacto puede variar, pero el filtrado antialiasing debe preceder al remuestreo y las particiones deben impedir fugas entre datos relacionados.	13
2.8	Esquema de clasificación contextual de palabras. Cada evento lingüístico define una ventana cerebral; las representaciones locales se contextualizan y se proyectan al espacio de un modelo de lenguaje para recuperar las palabras más próximas.	18
4.1	Resumen del preentrenamiento y del ajuste fino de MEG-XL. El modelo aprende primero a reconstruir tokens cerebrales en contextos largos y posteriormente reutiliza esas representaciones en una tarea contrastiva de clasificación contextual de palabras. Adaptado conceptualmente de Jayalath y Parker Jones.	31
4.2	Diseño experimental de la adaptación de MEG-XL a EEG-XL. Las tres rutas autosupervisadas mantienen el mismo currículo de lectura-escucha y difieren en la inicialización y en el embedding de tipo de sensor; el control supervisado permite separar el efecto del preentrenamiento EEG de la evaluación directa sobre ds004408.	33
4.3	Preprocesamiento EEG: filtrado, remuestreo, normalización, ventanas, montaje común y máscaras.	34
4.4	Arquitectura EEG-XL: BioCodec, códigos RVQ, embeddings, Transformer criss-cross y predicción de tokens enmascarados.	37
4.5	Ajuste y evaluación de palabras: ventanas alineadas, contexto EEG-XL, proyección cerebral, objetivo T5 y recuperación por ranking.	39
5.1	Precisión de validación durante el preentrenamiento autosupervisado . . .	48
5.2	Precisión Top-10 balanceada con 250 palabras en ds004408	49

Índice de tablas

2.1	Comparación general entre EEG y MEG [24, 22].	12
2.2	Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.	14
2.3	Comparación de trabajos relevantes en decodificación no invasiva del lenguaje.	21
3.1	Conjuntos de datos utilizados para el preentrenamiento y la evaluación de MEG-XL.	26
3.2	Resumen de los conjuntos de datos utilizados y su función dentro del proceso experimental. En ds007808, las horas de <i>listeningcovert</i> corresponden a grabaciones completas utilizadas como contexto y no a 167 horas de objetivos exclusivamente auditivos.	30
4.1	Resumen de la arquitectura y número de parámetros del modelo EEG. . .	36
5.1	Condiciones incluidas en la evaluación experimental.	41
5.2	Particiones utilizadas durante las dos etapas del preentrenamiento autosupervisado.	42
5.3	Configuración común del preentrenamiento autosupervisado.	44
5.4	Configuración común del ajuste supervisado sobre OpenNeuro ds004408.	46
5.5	Resultados de validación del preentrenamiento autosupervisado. El checkpoint se selecciona por mínima pérdida global de validación dentro de cada etapa.	47
5.6	Resultados de test del ajuste supervisado sobre OpenNeuro ds004408. Cada fila utiliza el checkpoint seleccionado mediante la mayor Top-10 balanceada sobre 250 palabras en validación.	49
5.7	Cobertura de los vocabularios de recuperación en la partición de test de ds004408. Los ejemplos excluidos corresponden a palabras fuera del vocabulario de recuperación considerado.	50
5.8	Diferencias descriptivas entre las condiciones experimentales, expresadas en puntos porcentuales sobre la partición de test.	50

Índice de acrónimos

BART	Bidirectional and Auto-Regressive Transformers.
BCI	Interfaz cerebro-computador, del inglés <i>brain-computer interface</i> .
BLEU	Bilingual Evaluation Understudy.
CBraMod	Modelo fundacional de EEG con atención <i>criss-cross</i> .
CTC	Connectionist Temporal Classification.
D-SigLIP	Variante de SigLIP usada como pérdida contrastiva con tratamiento de duplicados.
ECoG	Electrocorticografía.
EEG	Electroencefalografía.
EEGPT	Modelo Transformer preentrenado para EEG.
EEG-XL	Adaptación de MEG-XL a datos EEG propuesta en este trabajo.
ERP	Potencial relacionado con eventos, del inglés <i>event-related potential</i> .
fMRI	Resonancia magnética funcional, del inglés <i>functional magnetic resonance imaging</i> .
GPU	Unidad de procesamiento gráfico, del inglés <i>graphics processing unit</i> .
ICA	Análisis de componentes independientes.
LDA	Análisis discriminante lineal.
LaBraM	Large Brain Model.
M/EEG	Referencia conjunta a registros MEG y EEG.
MEG	Magnetoencefalografía.
MEG-MASC	Dataset MEG de escucha de habla natural usado en trabajos de decodificación.
MEG-XL	Modelo MEG de contexto largo que sirve como punto de partida del trabajo.
MTP	Predicción de tokens enmascarados, del inglés <i>masked token prediction</i> .
NR	Lectura natural, del inglés <i>natural reading</i> .
OPM	Magnetómetro de bombeo óptico, del inglés <i>optically pumped magnetometer</i> .
RVQ	Cuantización vectorial residual, del inglés <i>residual vector quantization</i> .
SigLIP	Sigmoid Loss for Language-Image Pre-training.
SQUID	Dispositivo superconductor de interferencia cuántica, del inglés <i>superconducting quantum interference device</i> .
SSS	Separación en el espacio de señal, del inglés <i>signal space separation</i> .
SVM	Máquina de vectores de soporte, del inglés <i>support vector machine</i> .
T5	Text-to-Text Transfer Transformer.

CAPÍTULO 1

Introducción

???? ????????????? ????????????? ????????????? ????????????? ?????????????

1.1 Motivación

Origen video intracortical ????? ????????????? ????????????? ????????????? ?????????????
????????????

1.2 Objetivos

???? ????????????? ????????????? ????????????? ????????????? ?????????????

1.3 Estructura de la memoria

???? ????????????? ????????????? ????????????? ????????????? ?????????????

CAPÍTULO 2

Marco teórico

2.1 Interfaces cerebro-computador

Las interfaces cerebro-computador (BCIs) son sistemas que establecen un canal de comunicación entre la actividad cerebral de una persona y un dispositivo externo [58]. Una BCI funciona de forma parecida a un ratón o una pantalla táctil, solo que intenta interpretar directamente determinados patrones de actividad neuronal y transformarlos en una salida útil. Esta salida puede ser desde mover un cursor o seleccionar una letra hasta controlar una prótesis o generar una secuencia de texto.

Durante los últimos años el interés por este tipo de sistemas ha aumentado considerablemente [19]. Además del trabajo que se está desarrollando en universidades y centros clínicos, la aparición de iniciativas privadas de gran visibilidad, como Neuralink, ha contribuido a acercar las BCIs al debate público [37]. Sin embargo, más allá de las expectativas generadas alrededor de estas tecnologías, su desarrollo sigue planteando dificultades.

De forma más o menos general, una BCI se puede dividir en varias etapas (véase Figura 2.1). En primer lugar, la actividad cerebral se registra mediante una modalidad de adquisición, como la electroencefalografía (EEG), magnetoencefalografía (MEG), resonancia magnética funcional (fMRI) o electrocorticografía (ECoG). Después, la señal obtenida se preprocesa para reducir ruido, artefactos y diferencias de escala. A continuación se extrae una representación de la señal preprocesada que conserve la información relevante para la tarea. Finalmente, un modelo de decodificación transforma dicha representación en una predicción y, en los sistemas en línea, esta predicción se utiliza para actuar sobre un dispositivo o proporcionar *feedback* al usuario [19].




Figura 2.1: Etapas generales de una interfaz cerebro-computador. La salida del decodificador puede utilizarse directamente o cerrar el bucle mediante realimentación al usuario.

No todas las BCIs persiguen el mismo objetivo. Algunas BCIs persiguen reconocer actividad generada voluntariamente por el usuario, como la imaginación motora o el habla imaginada. Otras BCIs son sistemas pasivos que no buscan ejecutar una orden, sino

estimar estados como la carga cognitiva, la atención o la fatiga [61, 19]. Con independencia del objetivo, hay una línea de investigación que es muy ambiciosa, ya que pretende recuperar información lingüística directamente a partir de la actividad neuronal: la decodificación cerebral del lenguaje.

2.1.1. Decodificación cerebral del lenguaje

Se llama decodificación cerebral del lenguaje a la tarea de producir información relacionada con el habla o la lectura a partir de señales cerebrales. Dependiendo del experimento, esta decodificación puede centrarse en fonemas, sílabas, palabras, frases completas o propiedades semánticas de los datos que proporciona el participante. Cuando el objetivo final es reconstruir texto de forma continua, se suele emplear el término *brain-to-text*. No obstante, antes de alcanzar una transcripción completa, gran parte de la investigación se centra en tareas intermedias más sencillas y controladas, como la detección de presencia de habla, la clasificación de fonemas o la identificación de palabras dentro de un vocabulario limitado [40, 28].

Hay diferentes situaciones o tareas en las que el lenguaje puede estar presente, resumidas en la Figura 2.2. En el *habla producida* o *overt speech*, la persona pronuncia en el experimento una palabra o una frase. Así se puede comprobar fácilmente el contenido generado, pero introduce las señales neurológicas relacionadas con el movimiento muscular de la boca, la lengua y la mandíbula. En el *habla imaginada*, llamada *covert speech*, *inner speech* o *habla interna*, lo que hace la persona es imaginar que pronuncia el contenido sin mover voluntariamente ningún músculo ni generar sonido. Esta segunda tarea resulta especialmente interesante para personas que han perdido la capacidad motora del habla pero no la cognitiva, que son el público objetivo de este tipo de experimentos y sistemas, aunque también es más difícil de registrar y verificar [42, 2].

Una tercera posibilidad y en la que se desarrolla este trabajo es estudiar la percepción del habla. En el *habla percibida*, el participante escucha palabras, frases o narraciones mientras se registra su actividad cerebral. Al existir un estímulo acústico conocido, es posible alinear con precisión los eventos lingüísticos con la señal neuronal. Aunque escuchar habla no equivalga a producirla o imaginarla, resulta más adecuada que los anteriores para estudiar representaciones lingüísticas y desarrollar modelos de decodificación no invasiva a gran escala [40].

Por último, dentro de la percepción del habla existe la opción de utilizar la lectura en lugar de la escucha. En este caso, la actividad cerebral que se registra mientras el participante procesa palabras presentadas de forma aislada o dentro de frases. La lectura natural introduce una dificultad adicional: cada persona fija la mirada sobre las palabras durante intervalos diferentes y puede omitir o volver a leer fragmentos del texto. Por este motivo, algunos conjuntos de datos combinan EEG y seguimiento ocular. El *eye-tracking* permite localizar el inicio y la duración de cada fijación y, a partir de esta información, extraer segmentos de EEG asociados a palabras concretas [17, 26].

La señal relacionada con una palabra tiene más profundidad que simplemente el instante exacto en el que esta aparece. El procesamiento lingüístico tiene dependencias a diferentes escalas temporales. Los fonemas se agrupan en sílabas, las sílabas en palabras y las palabras adquieren diferentes significados dentro de frases y discursos. Además, la respuesta cerebral a una palabra puede depender de las palabras anteriores, de las expectativas del lector u oyente y del estado general del participante. Por ello, los enfoques recientes no solo analizan ventanas aisladas, sino secuencias de segmentos neuronales consecutivos. Esta incorporación de contexto permite al modelo utilizar relaciones entre

palabras y patrones cerebrales que no son visibles cuando cada segmento se procesa de manera independiente [10, 30].

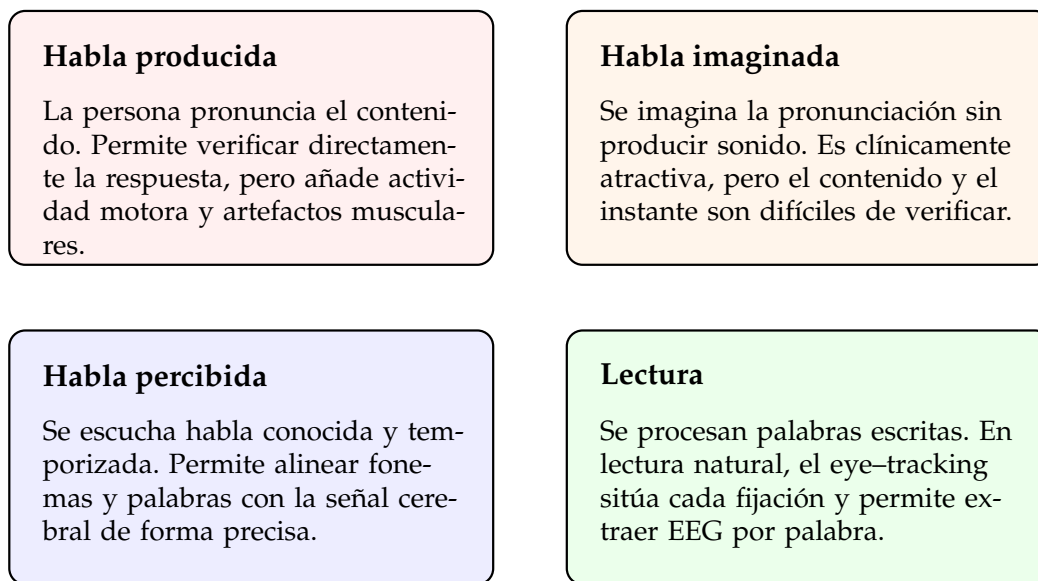


Figura 2.2: Principales paradigmas experimentales utilizados en decodificación cerebral del lenguaje. Cada paradigma ofrece un compromiso distinto entre naturalidad, facilidad de alineamiento y presencia de artefactos.

2.1.2. Métodos invasivos y no invasivos

Las técnicas utilizadas para registrar actividad cerebral se pueden dividir, de forma muy general, en métodos invasivos y no invasivos. Los métodos invasivos requieren una intervención quirúrgica para situar los sensores o sobre la superficie del cerebro o dentro del tejido cerebral. Entre ellos se encuentran la ECoG y los conjuntos de microelectrodos intracorticales [48].

La principal ventaja de los métodos invasivos es la calidad de la señal. Al encontrarse tan cerca de donde se genera la actividad neuronal, los electrodos registran señales con mayor amplitud, mejor resolución espacial y menos atenuación que los sensores externos. Esta proximidad ha permitido obtener resultados muy destacados en decodificación tanto motora como del habla. En particular, algunos sistemas invasivos han conseguido reconstruir texto o sintetizar voz en personas con parálisis a partir de actividad cortical relacionada con los intentos del habla [48, 57, 36]. Sin embargo, estas prestaciones se obtienen a cambio de riesgos quirúrgicos y postoperatorios. Por estos motivos, su utilización suele restringirse a casos clínicos muy concretos y entornos de investigación controlados.

Los métodos no invasivos, en cambio, registran la actividad cerebral sin necesidad de cirugía. Dentro de este grupo se encuentran sobre todo EEG, MEG y resonancia magnética (fMRI). Estas técnicas reducen considerablemente los riesgos para el participante y permiten realizar estudios replicables con mayor facilidad. Su principal limitación es la calidad de la señal, ya que debe atravesar diferentes tejidos o medirse a cierta distancia de su origen, lo que disminuye su resolución y añade mucho ruido [24, 22]. La Figura 2.3 ilustra esta diferencia general entre una adquisición invasiva y una alternativa no invasiva.

Dentro de estos métodos, EEG y MEG destacan por su elevada resolución temporal. Ambas modalidades permiten seguir cambios cerebrales del orden de milisegundos, esta propiedad es muy importante para estudiar procesos tan rápidos como es la percepción




Figura 2.3: Ejemplos de adquisición invasiva y no invasiva. A la izquierda, un registro ECoG ilustra la proximidad de los electrodos a la corteza. A la derecha, la fMRI muestra una alternativa no invasiva.

Fuentes: izquierda, Kathrin Czoppelt / TUM Klinikum; derecha, Cadena SER Cantabria, <https://cadenaser.com/cantabria/2023/05/06/el-hospital-de-laredo-contara-con-una-resonancia-magnetica-ser-castro-urdiales/>.

de fonemas o palabras. La resonancia magnética funcional ofrece una mejor resolución espacial, pero su respuesta es mucho más lenta y dificulta la separación temporal de palabras consecutivas. EEG y MEG constituyen, por tanto, un compromiso especialmente interesante entre seguridad y capacidad para representar la dinámica temporal del lenguaje [24, 22].

2.2 Aprendizaje profundo

El aprendizaje profundo es una rama del aprendizaje automático especializada en el aprendizaje de grandes modelos neuronales. Este tipo de aprendizaje permite aprender representaciones directamente a partir de datos de alta dimensión [34]. Comparado con los métodos clásicos, que dependen en mayor medida de características diseñadas manualmente, una red neuronal puede optimizar conjuntamente la extracción de patrones y la tarea final. Esta propiedad ha hecho que las redes profundas se utilicen en dominios muy diferentes, como visión por computador, procesamiento del lenguaje, audio o señales temporales.

Sin embargo, utilizar modelos neuronales más grandes no siempre significa obtener un mejor resultado. Una arquitectura con demasiados parámetros puede memorizar particularidades del conjunto de entrenamiento y generalizar mal a datos nuevos [64]. Por este motivo, el diseño del modelo debe acompañarse de regularización, particiones rigurosas, múltiples semillas y comparaciones frente a modelos sencillos.

2.2.1. Redes neuronales y Transformers

Una red neuronal transforma una entrada mediante una sucesión de capas parametrizadas. Cada capa combina los valores de la anterior y aplica una función no lineal. Durante el entrenamiento, los parámetros se ajustan para reducir una función de pérdida (*loss*). En clasificación, esta *loss* mide la diferencia entre lo que predice el modelo y las etiquetas reales. En aprendizaje de representaciones, puede medir la capacidad para reconstruir una entrada o acercar ejemplos relacionados.

Las redes totalmente conectadas pueden utilizarse sobre vectores de características, pero no aprovechan de forma explícita la estructura local de una señal o una imagen. Las

redes convolucionales, conocidas como CNNs, aplican filtros locales que se desplazan por la entrada. En una señal temporal, una convolución puede detectar patrones cortos que aparecen en distintos momentos, mientras que las convoluciones dilatadas aumentan el campo receptivo sin necesitar un número excesivo de capas [13, 10].

Los Transformers sustituyen la recurrencia por mecanismos de atención [52]. Para una secuencia de vectores, cada elemento se transforma en una consulta, una clave y un valor. La atención calcula la similitud entre consultas y claves y utiliza estos pesos para combinar los valores:

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d}}\right) \mathbf{V}.$$

Gracias a este mecanismo, una posición puede acceder directamente a cualquier otra posición de la secuencia. Esto resulta útil cuando la predicción de un elemento depende de información situada en otro punto del contexto.

El modelo necesita también información sobre el orden. Los *embeddings* posicionales, ya sean aprendidos, sinusoidales o rotatorios, indican la posición temporal de cada elemento. Sin ellos, el mecanismo de atención trataría la secuencia como un conjunto sin orden. La atención completa tiene, no obstante, un coste cuadrático respecto al número de elementos, por lo que las secuencias largas suelen requerir variantes eficientes, atención local o factorizaciones de la atención.

2.2.2. Aprendizaje autosupervisado y transferencia de aprendizaje

El aprendizaje supervisado necesita pares de entrada y etiqueta. Cuando las etiquetas son escasas o costosas, el aprendizaje autosupervisado intenta aprovechar datos sin anotaciones manuales. La propia entrada proporciona el objetivo de entrenamiento: por ejemplo, se puede ocultar una parte de ella y pedir al modelo que la reconstruya a partir del contexto. Esta estrategia se utiliza en modelos de lenguaje enmascarado, audio y visión [15, 5].

Después del preentrenamiento se realiza una adaptación o *fine-tuning*. El modelo recibe ejemplos de la tarea final y sus parámetros se ajustan para resolverla. Si las representaciones aprendidas son útiles, el modelo necesita menos datos etiquetados que uno inicializado aleatoriamente. Otra forma de evaluación es el *linear probing*, donde el modelo preentrenado se mantiene congelado y solo se entrena una capa lineal. Este procedimiento mide la calidad de las representaciones sin permitir que toda la red se adapte a la nueva tarea [41].

La transferencia de aprendizaje (*transfer learning*) puede realizarse entre tareas, conjuntos de datos o dominios. Para que sea efectiva, es necesario distinguir entre componentes generales y específicos del dominio. Las primeras capas pueden aprender patrones básicos reutilizables, mientras que otras partes del modelo pueden depender fuertemente de la distribución de entrenamiento. Asimismo, debe considerarse la transferencia negativa: un modelo preentrenado puede rendir peor si las representaciones aprendidas no son adecuadas para el nuevo dominio. Por ello, la transferencia debe compararse con un modelo entrenado desde cero utilizando la misma arquitectura y los mismos datos [41].

2.3 Electroencefalografía y magnetoencefalografía

Las corrientes que provienen del proceso de la sinapsis en el cerebro producen tanto potenciales eléctricos (EEG) como campos magnéticos (MEG). EEG registra las dife-

rencias de potencial que llegan al cuero cabelludo, mientras que MEG mide los campos magnéticos producidos alrededor de la cabeza. Pese a que ambas modalidades ofrecen una resolución temporal elevada, sus propiedades físicas, su distribución espacial y sus sistemas de adquisición son diferentes [24, 22].

Esta diferencia entre 2 métodos que pueden parecer similares a primera vista es importante, sobre todo al tratar de realizar una transferencia de un tipo de método al otro. EEG no recibe directamente la actividad de las fuentes cerebrales, sino una mezcla de dichas fuentes observada a través de una disposición concreta de sensores, como se esquematiza en la Figura 2.4. Por tanto, cambiar de MEG a EEG no consiste únicamente en modificar el número de canales. También cambian la amplitud, la geometría, el tipo de ruido, la referencia y la relación entre cada sensor y las fuentes neuronales [24, 22].




Figura 2.4: Esquema conceptual de la observación de una fuente neuronal mediante EEG y MEG.

2.3.1. Electroencefalografía

La EEG registra diferencias de potencial eléctrico utilizando electrodos colocados sobre el cuero cabelludo. Estas diferencias se producen por la actividad sincronizada de grandes poblaciones de neuronas corticales. La amplitud registrada suele ser muy pequeña, en el orden de los microvoltios ($1 \mu\text{V} = 10^{-6} \text{ V}$), por lo que el sistema de adquisición necesita amplificar señales muy pequeñas y mantener un buen contacto entre los electrodos y la piel [24].

La colocación de estos electrodos suele seguir sistemas estandarizados, como el sistema internacional 10–20 y sus extensiones 10–10 o 10–5 [27, 39]. Estos sistemas asignan diferentes nombres a las posiciones en función de la región aproximada de la cabeza: frontal, central, temporal, parietal y occipital. En montajes de alta densidad se pueden utilizar 64, 128 o incluso más canales, distribuidos mediante gorros como el mostrado en la Figura 2.5. Un mayor número de electrodos proporciona una observación espacial más detallada, aunque también incrementa el tiempo de preparación, la posibilidad de canales defectuosos y el coste computacional.



Figura 2.5: Ejemplo de gorro EEG con electrodos distribuidos sobre el cuero cabelludo. Fuente: MedRent, <https://www.medrent.mx/co/productos/starstim-8>.

Asimismo, hay que tener en cuenta que EEG es una medida relativa. Cada canal de EEG representa la diferencia entre un electrodo y una referencia o una combinación de ellas. La elección de esta referencia afecta a la forma de la señal y debe tenerse en cuenta al comparar conjuntos de datos. Entre las opciones habituales se encuentran la referencia a un electrodo concreto, la referencia promedio de todos los canales o las configuraciones bipolares. En conjuntos de datos que están recogidos con diferentes sistemas, una estrategia de referencia homogénea puede reducir parte de las diferencias, pero no elimina por completo la variabilidad entre los montajes [60].

Como se ha indicado antes, una de las principales ventajas de EEG es su resolución temporal. Es capaz de registrar frecuencias de cientos o miles de muestras por segundo, lo que permite estudiar respuestas rápidas asociadas a estímulos visuales, auditivos o lingüísticos. A su vez es una tecnología –relativamente– económica, portátil y compatible con experimentos más fieles al uso que tendrían los modelos. Estas características explican su uso frecuente en BCI y en estudios de lectura, donde puede combinarse con seguimiento ocular para obtener segmentos asociados a cada fijación [26].

Su principal limitación es la resolución espacial. Los potenciales eléctricos se propagan a través del cerebro, el líquido cefalorraquídeo, el cráneo y el cuero cabelludo. La conductividad de estos tejidos produce un fenómeno de difusión conocido como conducción de volumen, por el cual una misma fuente puede afectar a numerosos electrodos. Como consecuencia, la actividad que se observa en un canal no puede asociarse directamente a una única región cerebral [24, 22].

Por otro lado, las señales EEG pueden contaminarse con actividad que no procede directamente del cerebro (estas contaminaciones se llaman artefactos). Los parpadeos y movimientos oculares generan señales de gran amplitud en los electrodos frontales. La tensión muscular, el movimiento de la mandíbula, el latido cardíaco, el desplazamiento de los cables y el contacto deficiente de los electrodos pueden ocultar la actividad neuronal. En tareas de habla producida, los artefactos musculares son especialmente relevantes. En lectura natural, los movimientos oculares forman parte de la propia tarea,

de modo que su tratamiento debe realizarse con cuidado para no eliminar información relacionada indirectamente con el procesamiento lingüístico [14].

2.3.2. Magnetoencefalografía

Por su parte, la magnetoencefalografía (MEG) registra los campos magnéticos generados por la actividad neuronal. La magnitud física medida es la densidad de flujo magnético, cuya unidad en el Sistema Internacional es el tesla (T); un tesla equivale a un weber por metro cuadrado. Puesto que esta unidad resulta demasiado grande para describir la actividad cerebral, las señales MEG suelen expresarse en femtoteslas, donde $1 \text{ fT} = 10^{-15} \text{ T}$. Los campos producidos por la actividad neuronal suelen encontrarse en el rango de decenas o centenares de femtoteslas, mientras que el campo magnético terrestre es del orden de decenas de microteslas. Por tanto, las señales cerebrales pueden ser entre ocho y diez órdenes de magnitud menores que el campo ambiental [24]. Esta diferencia permite interpretar la elevada sensibilidad requerida y explica por qué las mediciones deben realizarse mediante sensores especializados dentro de salas magnéticamente apantalladas.

Los sistemas MEG tradicionales emplean dispositivos superconductores de interferencia cuántica, conocidos como SQUID por sus siglas en inglés (*Superconducting Quantum Interference Devices*). Estos dispositivos permiten detectar variaciones extremadamente pequeñas del flujo magnético, pero deben funcionar en régimen superconductor a temperaturas criogénicas, por lo que se alojan en un criostato que mantiene los sensores separados físicamente de la cabeza del participante [24]. Asimismo, se están desarrollando sistemas basados en magnetómetros de bombeo óptico u OPM (*Optically Pumped Magnetometers*), que no requieren superconductividad ni un criostato. Esto permite situar los sensores más cerca del cuero cabelludo, adaptar su distribución a la forma y el tamaño de cada cabeza y construir dispositivos más flexibles y tolerantes al movimiento [6].

Los sistemas MEG suelen incluir dos tipos de sensores: magnetómetros y gradiómetros. Los magnetómetros miden directamente una componente de la densidad de flujo magnético en la posición del sensor. Los gradiómetros, en cambio, registran la diferencia entre las medidas obtenidas en dos bobinas próximas, proporcionando una aproximación al gradiente espacial del campo. Como las fuentes ambientales lejanas tienden a producir campos similares en ambas bobinas, esta diferencia permite atenuar parte de las interferencias externas. Un equipo MEG de cuerpo completo puede contener más de trescientos canales distribuidos alrededor de la cabeza. Por ejemplo, LibriBrain fue registrado con un sistema MEGIN Triux Neo de 306 canales [40].

A diferencia de los potenciales eléctricos, los campos magnéticos atraviesan el cráneo y el cuero cabelludo con una distorsión menor, debido a que la permeabilidad magnética de estos tejidos es muy similar a la del espacio que los rodea. Esto proporciona a MEG una resolución espacial superior a la de EEG en muchas condiciones, manteniendo una resolución temporal del orden de milisegundos [24, 22]. Estas propiedades han convertido MEG en una modalidad especialmente utilizada para estudiar la percepción auditiva, el lenguaje y el habla continua [12].

MEG presenta, no obstante, limitaciones importantes. El equipamiento tiene un coste mucho más elevado que el de EEG, requiere instalaciones específicas y, en los sistemas SQUID convencionales, no es fácilmente transportable, como muestra el sistema de adquisición de la Figura 2.6. El participante debe permanecer relativamente quieto, ya que el movimiento de la cabeza modifica la relación espacial entre las fuentes cerebrales y los sensores. Además, los datos ocupan un volumen considerable y su procesamiento suele

incluir pasos específicos, como la corrección del movimiento de la cabeza, la detección de canales defectuosos y la reducción de señales procedentes del exterior del casco [22].



Figura 2.6: Ejemplo de adquisición mediante MEG. Fuente: Wikipedia, <https://es.wikipedia.org/wiki/Magnetoencefalograf%C3%ADa>.

Una de las técnicas empleadas con este último propósito es *Signal Space Separation* (SSS). Este método representa las mediciones mediante bases espaciales diferentes para los campos generados dentro del volumen que contiene la cabeza y para los campos originados fuera de este. De esta forma, pueden descartarse los componentes asociados principalmente a interferencias externas. SSS, junto con sus extensiones temporales y los procedimientos de compensación del movimiento, se implementa habitualmente mediante el denominado filtrado de Maxwell [50].

Otra propiedad relevante es que los sistemas MEG no comparten necesariamente la misma disposición de sensores. Distintos fabricantes utilizan cantidades, tipos y geometrías diferentes. Incluso dentro de un mismo sistema, la posición y orientación de la cabeza respecto al casco pueden cambiar entre participantes o sesiones. Para combinar datos de varios conjuntos, los modelos deben representar de algún modo la localización,

la orientación y el tipo de cada sensor, o transformar previamente las señales a un espacio común.

MEG ha permitido desarrollar algunos de los conjuntos de datos más relevantes para la decodificación no invasiva del habla. La menor distorsión por los tejidos y, en muchos diseños, una mejor localización efectiva, unidas a adquisiciones prolongadas, han facilitado tareas de detección de habla, clasificación de fonemas y clasificación contextual de palabras [24, 22]. Estos resultados hacen que los modelos preentrenados con MEG constituyan una base interesante para estudiar su transferencia a EEG, aunque las diferencias físicas, espaciales e instrumentales entre ambas modalidades impiden asumir que dicha transferencia será directa.

2.3.3. Comparación entre EEG y MEG

EEG y MEG comparten su carácter no invasivo y su elevada resolución temporal, pero presentan diferencias importantes en la forma en que observan la actividad cerebral. La Tabla 2.1 resume las propiedades más relevantes para este trabajo [24, 22].

Tabla 2.1: Comparación general entre EEG y MEG [24, 22].

Propiedad	EEG	MEG
Magnitud	Potencial eléctrico	Campo magnético
Temporal	Milisegundos	Milisegundos
Espacial	Menor; conducción de volumen; referencia	Mayor; menor distorsión tisular
Fuentes	Radiales; tangenciales	Principalmente tangenciales
Artefactos	Oculares; musculares; referencia; contacto	Movimiento; interferencias; musculares
Coste	Bajo; portátil	Alto; sala apantallada
Preparación	Electrodos; impedancias; referencia	Casco; sensores; posición; movimiento
Variabilidad	Montaje; referencia; amplificador; muestreo	Geometría; tipo de sensor; posición de cabeza

Desde el punto de vista del aprendizaje automático, ambas modalidades suelen representarse inicialmente como una matriz de canales por tiempo. Sin embargo, esta similitud de formato puede dar lugar a errores conceptuales. Los canales de EEG y MEG no son intercambiables, y una misma fuente cortical se proyecta de forma diferente en cada modalidad. Además, EEG suele tener menos canales y una relación señal-ruido inferior, mientras que MEG proporciona una estructura espacial más rica.

Estas diferencias generan un problema de cambio de dominio. Un modelo entrenado con MEG puede haber aprendido patrones que dependen de la geometría de sus sensores, de la amplitud de la señal o del tipo de ruido presente en el escáner. Al aplicarlo sobre EEG, estas relaciones dejan de cumplirse. Por ello, la transferencia requiere adaptar la entrada, normalizar la señal, representar la posición de los electrodos y, en muchos casos, reajustar parte o la totalidad del modelo [41, 59].

Aun así, EEG y MEG comparten información temporal y neurofisiológica. Ambas modalidades reflejan la actividad coordinada de poblaciones neuronales y contienen respuestas relacionadas con el procesamiento de palabras. Esta base común justifica estudiar si las representaciones aprendidas mediante preentrenamiento MEG pueden aportar información útil para EEG, especialmente en escenarios con pocos datos etiquetados. El

objetivo no es asumir que ambas señales son iguales, sino determinar qué partes del conocimiento aprendido son transferibles y qué componentes deben adaptarse [41, 59].

2.4 Procesamiento de señales cerebrales

Como se ha comentado previamente, las señales EEG y MEG se registran como series temporales multicanal. Si se utilizan C sensores y se obtienen T muestras, una grabación se puede representar como una matriz

$$\mathbf{X} \in \mathbb{R}^{C \times T}.$$

Además de información temporal y espacial, esta representación contiene ruido, artefactos y diferencias entre instrumentos. Antes de entrenar un modelo es necesario decidir qué parte de la señal se conserva, cómo se normaliza y cómo se divide en muestras.

El procesamiento es más que una simple limpieza previa, cada decisión modifica la información que el modelo puede utilizar. Un filtro demasiado restrictivo puede eliminar componentes relacionadas con la tarea, mientras que una limpieza insuficiente puede hacer que el sistema aprenda artefactos. Del mismo modo, una segmentación incorrecta puede asociar una etiqueta lingüística a una ventana que no contiene la respuesta cerebral correspondiente. La Figura 2.7 resume las etapas principales de este flujo.




Figura 2.7: Flujo habitual de preparación de registros EEG y MEG para aprendizaje automático. El orden exacto puede variar, pero el filtrado antialiasing debe preceder al remuestreo y las particiones deben impedir fugas entre datos relacionados.

2.4.1. Actividad oscilatoria y bandas de frecuencia

La actividad registrada mediante EEG y MEG suele estudiarse en el dominio de la frecuencia. En esta sección y durante el resto del trabajo se emplea el término frecuencia con dos significados diferentes. Por un lado, la frecuencia de muestreo, expresada en hercios, indica el número de valores de la señal registrados por segundo y determina su resolución temporal. Por otro, la frecuencia de las componentes de la señal describe el número de oscilaciones por segundo de la actividad registrada, como las asociadas a las distintas bandas cerebrales o a fuentes de ruido. Aunque ambas magnitudes se expresan en hercios, representan conceptos distintos: la primera describe cómo se digitaliza la señal, mientras que la segunda caracteriza su contenido espectral. La frecuencia que registran EEG y MEG es del primer tipo, representa el número de ciclos de una oscilación que se producen en un segundo y se expresa en hercios. De manera aproximada, estas oscilaciones suelen agruparse en las bandas delta, theta, alfa, beta y gamma. Esta división, resumida en la Tabla 2.2, permite describir cambios en la actividad cerebral y estudiar su relación con diferentes estados fisiológicos y procesos cognitivos.

Estas asociaciones deben entenderse de manera aproximada, ya que las bandas no representan componentes completamente independientes ni se corresponden de forma

Tabla 2.2: Principales bandas de frecuencia utilizadas en el análisis de señales EEG y MEG. Los límites y las asociaciones funcionales son aproximados.

Banda	Intervalo aproximado	Asociaciones habituales
Delta	0.5–4 Hz	Sueño profundo y actividad cerebral lenta.
Theta	4–8 Hz	Procesos de aprendizaje, memoria y control cognitivo.
Alfa	8–13 Hz	Estados de reposo, regulación de la atención e inhibición de información no relevante.
Beta	13–30 Hz	Procesamiento cognitivo y sensoriomotor activo.
Gamma	> 30 Hz	Integración de información y diferentes procesos perceptivos y cognitivos.

exclusiva con una única función cerebral. Su interpretación depende de la región registrada, de la tarea realizada y del momento analizado [9, 33, 20].

En los estudios de habla imaginada se han utilizado combinaciones muy diferentes de frecuencias, desde bandas bajas hasta intervalos gamma, sin que exista una banda universalmente óptima para todos los participantes, tareas y conjuntos de datos [42, 2]. Por este motivo, tanto los límites del filtrado como la frecuencia de muestreo deben considerarse decisiones relevantes cuando se adapta un modelo a nuevos conjuntos de EEG. Una frecuencia de muestreo reducida disminuye el coste computacional, pero limita las componentes espectrales que pueden conservarse.

2.4.2. Preprocesamiento de EEG y MEG

El primer paso suele ser comprobar la calidad de la grabación. Durante esta revisión se identifican canales planos, saturados o excesivamente ruidosos. Estos canales pueden eliminarse, interpolarse a partir de sensores vecinos o marcarse para que el modelo no los utilice. También es importante verificar la sincronización entre la señal cerebral y los eventos del experimento, especialmente cuando las ventanas se alinean con el inicio de una palabra, un estímulo auditivo o una fijación ocular [21].

En EEG, el preprocesamiento puede incluir una nueva referencia de los canales. La referencia promedio es una opción común en sistemas de alta densidad, aunque su idoneidad depende de la cobertura de electrodos. Del mismo modo se revisan las impedancias y se eliminan canales periféricos muy afectados por actividad muscular. En MEG no existe una referencia eléctrica equivalente, pero son habituales la corrección del movimiento de la cabeza y los métodos que separan las fuentes internas y externas al casco. En LibriBrain, por ejemplo, se aplica filtrado de Maxwell, eliminación de canales defectuosos, filtros para la red eléctrica y reducción de la frecuencia de muestreo [21, 40].

El filtrado temporal busca conservar un intervalo de frecuencias útil y reducir componentes no deseadas. Un filtro paso alto elimina las variaciones muy lentas y la deriva de la línea base. Un filtro paso bajo reduce el ruido de alta frecuencia y prepara la señal para un posible remuestreo. En EEG también se utilizan filtros *notch* en la frecuencia de la red eléctrica, que en Europa es de 50 Hz, y en algunos de sus armónicos. La elección de los límites debe estar relacionada con la tarea y con la nueva frecuencia de muestreo. Antes de reducir la frecuencia es necesario aplicar un filtrado *antialiasing* que elimine componentes superiores a la frecuencia de Nyquist [56]. Esta frecuencia corresponde a la mitad de la frecuencia de muestreo, es decir,

$$f_{\text{Nyquist}} = \frac{f_s}{2},$$

y determina la frecuencia máxima que puede representarse correctamente en una señal digital. Las componentes situadas por encima de este límite pueden aparecer como frecuencias más bajas tras el remuestreo, dando lugar al fenómeno de *aliasing*.

El remuestreo reduce la cantidad de puntos temporales y, por tanto, el coste de almacenamiento y entrenamiento. Esta reducción es especialmente importante en modelos de contexto largo, donde el número de elementos de entrada crece con la duración, el número de canales y la frecuencia de muestreo. Ni en EEG ni en MEG existe una frecuencia óptima universal para la decodificación de palabras, por lo que su selección debe evaluarse experimentalmente siempre.

La eliminación de artefactos es uno de los pasos más delicados. A pesar de su utilidad, esta eliminación no está exenta de riesgos. En una tarea de lectura, la actividad ocular está relacionada con el momento en que se procesa cada palabra. Eliminar toda señal correlacionada con los ojos podría suprimir parte de la estructura temporal necesaria para la alineación. De manera similar, en habla producida, un modelo puede alcanzar una precisión elevada utilizando actividad muscular en lugar de actividad cerebral. Por ello, el tratamiento de artefactos debe ajustarse al objetivo del experimento y acompañarse de controles que permitan detectar atajos no deseados [25].

Después del filtrado, las señales suelen normalizarse. Una normalización global puede verse dominada por diferencias entre sesiones o por valores extremos. Por este motivo, se utilizan estrategias por canal, por grabación o por segmento. Entre ellas se encuentran la estandarización mediante media y desviación típica, la normalización robusta mediante mediana y rango intercuartílico y el recorte de valores extremos.

La última etapa es la segmentación. En clasificación de palabras, cada ejemplo se obtiene normalmente a partir de una ventana alineada con un evento lingüístico. En escucha, este evento puede ser el inicio de la palabra en el audio. En lectura, puede ser el momento en que comienza una fijación sobre la palabra. La ventana puede incluir señal anterior al evento para corregir la línea base y señal posterior para capturar respuestas tardías. Cuando se procesan secuencias completas, varias ventanas consecutivas se agrupan manteniendo su orden original.

Asimismo, la división entre entrenamiento, validación y prueba forma parte del procesamiento. No es suficiente con separar ventanas aleatoriamente si segmentos cercanos pertenecen a la misma grabación o al mismo estímulo. Esto puede producir fugas de información, ya que el modelo reconoce propiedades específicas de la sesión o del contenido. Siempre que sea posible, deben mantenerse sesiones, sujetos o estímulos completos dentro de una única partición. En conjuntos donde varios participantes reciben el mismo estímulo, todas las repeticiones de dicho estímulo deben asignarse a la misma partición [25].

2.4.3. Representación temporal y espacial de las señales

La forma más directa de representar EEG o MEG es utilizar la matriz original de canales por tiempo. Esta opción conserva la señal con pocas suposiciones previas y permite que los modelos aprendan sus propias características. Sin embargo, exige una arquitectura capaz de manejar secuencias largas, diferencias de escala y relaciones entre sensores [44].

Si ese no es el caso, una alternativa clásica consiste en extraer características temporales o estadísticas, como media, varianza, potencia, coeficientes autorregresivos o amplitud de potenciales relacionados con eventos. Estas representaciones reducen la dimensionalidad, pero dependen de decisiones manuales y pueden perder información. En habla

imaginada se han utilizado además características de conectividad, patrones espaciales comunes y matrices de covarianza [42, 2].

Las representaciones tiempo-frecuencia describen cómo cambia el contenido espectral a lo largo de la señal. Para obtenerlas se emplean transformadas de Fourier de tiempo corto, bancos de filtros o transformadas wavelet. El resultado puede visualizarse como un espectrograma o escalograma [10, 44]. Estas imágenes permiten aplicar redes convolucionales desarrolladas originalmente para visión. No obstante, convertir una señal multicanal en una imagen obliga a decidir cómo se colocan los sensores y cómo se combinan sus dimensiones. Una representación inadecuada puede mezclar canales sin respetar su posición real.

La dimensión espacial puede modelarse de varias formas. En EEG, la disposición de los electrodos sobre la cabeza se puede proyectar a un mapa bidimensional. En MEG, se dispone de la posición y orientación tridimensional de los sensores, además de su tipo. Además, pueden utilizarse matrices de covarianza o correlación para representar la relación entre canales. Otra posibilidad es reconstruir las fuentes corticales y trabajar en espacio cerebral, aunque este proceso requiere modelos anatómicos y añade una etapa de estimación.

Estas decisiones de representación condicionan después qué arquitectura puede utilizarse. Un modelo temporal necesita conservar el orden de las muestras, un modelo espacial necesita información sobre la disposición de los sensores y un modelo contextual necesita agrupar ventanas consecutivas sin mezclar ejemplos que pertenezcan a divisiones distintas.

La representación temporal depende de la longitud del contexto. Los métodos basados en palabras aisladas utilizan ventanas de unos pocos segundos y predicen cada ejemplo de forma independiente. Los modelos contextuales reciben secuencias de ventanas y pueden relacionar la respuesta de una palabra con las anteriores y posteriores.

El contexto largo no implica conservar únicamente frecuencias lentas. Un filtro paso alto puede eliminar deriva de muy baja frecuencia y, aun así, el modelo puede aprender dependencias estadísticas entre eventos separados por varios segundos o minutos. La frecuencia de la señal indica la velocidad de sus oscilaciones, mientras que el contexto determina durante cuánto tiempo puede relacionar el modelo diferentes patrones. Son conceptos distintos y ambos influyen en la información disponible.

2.4.4. Aprendizaje profundo aplicado a EEG y MEG

Al aplicar aprendizaje profundo a EEG y MEG, una de las decisiones más importantes es cómo conservar la estructura multicanal de la señal. Si los sensores se tratan solo como índices, el modelo puede perder información sobre la posición real de cada medida. Por ello, algunos modelos añaden *embeddings* que describen cada sensor: posición, orientación y tipo en MEG, o coordenadas de los electrodos en EEG. Esta información permite trabajar con montajes distintos sin asumir que el canal i representa lo mismo en todos los sistemas [10, 59, 30].

También importa en qué momento se mezclan las dimensiones temporal y espacial. Una compresión temprana de todos los canales en un único vector simplifica la entrada, pero puede ocultar relaciones entre sensores o dificultar la adaptación a otro montaje. En cambio, mantener separados tiempo y canales durante las primeras etapas permite que el modelo aprenda patrones temporales dentro de cada sensor y combinaciones espaciales entre sensores cuando la tarea lo requiera [44, 30].

Esta separación es especialmente relevante cuando se usan tokenizers o modelos pre-entrenados. Un tokenizer puede reducir la longitud temporal y hacer viable el procesamiento de contextos largos, pero también impone las propiedades de los datos con los que fue entrenado. Si su frecuencia de muestreo, filtrado o forma de combinar canales no encaja con el conjunto EEG objetivo, la cuantización puede descartar información útil antes de que el modelo contextual la utilice. Por tanto, en la adaptación de modelos MEG a EEG no basta con reutilizar el codificador: hay que comprobar si la representación intermedia sigue conservando las diferencias necesarias para clasificar palabras [51, 62, 4, 30].

2.5 Decodificación contextual de palabras

La clasificación de palabras intenta identificar qué palabra está asociada a un segmento de actividad cerebral. En el caso más sencillo, cada ventana se procesa de forma independiente y el modelo devuelve una distribución sobre un vocabulario fijo. En la decodificación contextual, esquematizada en la Figura 2.8, el modelo recibe varias ventanas consecutivas y produce una predicción para cada una, teniendo en cuenta las relaciones dentro de la secuencia.

Este enfoque se sitúa entre la clasificación aislada y la reconstrucción completa de texto. Sigue trabajando con un vocabulario cerrado y con eventos previamente alineados, pero introduce información lingüística y neural de las palabras vecinas. Esto permite estudiar si el contexto mejora la representación antes de añadir mecanismos más complejos de búsqueda, reordenación o generación de palabras fuera del vocabulario.

2.5.1. Representaciones lingüísticas

Una clasificación convencional representa cada clase mediante un identificador independiente. En este caso, las palabras *perro*, *gato* y *mesa* estarían igual de separadas entre sí, aunque las dos primeras compartan propiedades semánticas. Este planteamiento obliga al modelo a aprender cada palabra como una categoría aislada.

Los *embeddings* lingüísticos representan palabras mediante vectores continuos. Palabras utilizadas en contextos parecidos tienden a ocupar posiciones próximas en el espacio. Los modelos de lenguaje modernos generan representaciones contextuales, de modo que el vector asociado a una palabra también depende de la frase en la que aparece. Esta propiedad resulta útil para la decodificación cerebral, ya que la respuesta neuronal a una palabra tampoco es completamente independiente de su contexto.

Los enfoques recientes utilizan representaciones extraídas de modelos Text-To-Text Transfer Transformer (T5) [43]. Para cada palabra del vocabulario se obtiene un vector de una capa intermedia del modelo de lenguaje. Si una palabra se divide en varios tokens, sus representaciones pueden promediarse para construir un único objetivo a nivel de palabra. El decodificador cerebral no predice directamente una etiqueta, sino un vector que debe aproximarse al *embedding* lingüístico correspondiente [10, 40].

Durante la inferencia, el vector neuronal predicho se compara con los vectores de todas las palabras del conjunto de recuperación. La palabra elegida es la que presenta mayor similitud coseno:

$$\hat{y} = \arg \max_{y \in \mathcal{V}} \frac{\hat{\mathbf{w}}^\top \mathbf{w}_y}{\|\hat{\mathbf{w}}\| \|\mathbf{w}_y\|},$$

donde $\hat{\mathbf{w}}$ es la representación predicha a partir de la señal cerebral, $\mathbf{w}_y$ es la representación de la palabra y y $\mathcal{V}$ es el vocabulario.

Este planteamiento permite aprovechar la estructura semántica aprendida por el modelo de lenguaje. Una predicción incorrecta puede quedar cerca de palabras relacionadas en lugar de ser completamente arbitraria. Además, la misma arquitectura puede adaptarse a vocabularios diferentes cambiando el conjunto de vectores de recuperación. No obstante, el modelo continúa limitado por las palabras incluidas en dicho conjunto.

El tamaño del vocabulario introduce un compromiso. Un vocabulario pequeño contiene menos opciones y facilita la clasificación, pero cubre una parte menor del texto. Un vocabulario grande se aproxima mejor al lenguaje natural, aunque reduce la precisión y necesita más ejemplos por clase. LibriBrain evalúa la clasificación sobre las 250 palabras más frecuentes, que cubren una proporción importante del contenido del corpus [40]. MEG-XL utiliza también conjuntos más reducidos en algunos experimentos para analizar el rendimiento en escenarios con pocos datos [30].

La frecuencia de las palabras es otro factor importante. Las palabras funcionales, como artículos y preposiciones, aparecen muchas veces y suelen clasificarse mejor que palabras de contenido menos frecuentes. Por ello, una precisión global puede estar dominada por unas pocas clases frecuentes. Las métricas equilibradas y los análisis por frecuencia ayudan a comprobar si el modelo aprende todo el vocabulario o únicamente las palabras más repetidas.




Figura 2.8: Esquema de clasificación contextual de palabras. Cada evento lingüístico define una ventana cerebral; las representaciones locales se contextualizan y se proyectan al espacio de un modelo de lenguaje para recuperar las palabras más próximas.

2.5.2. Aprendizaje contrastivo

El aprendizaje contrastivo busca acercar representaciones correspondientes y separar representaciones no relacionadas. En la clasificación de palabras, cada segmento cerebral y su palabra real forman un par positivo. Las demás palabras del lote pueden utilizarse como ejemplos negativos. El modelo aprende un espacio común en el que la representación neuronal se aproxima a su objetivo lingüístico [63].

Si $\mathbf{r}_i$ es la representación cerebral del ejemplo i y $\mathbf{w}_j$ es el *embedding* de la palabra j , se puede construir una matriz de similitudes

$$s_{ij} = \frac{\mathbf{r}_i^\top \mathbf{w}_j}{\|\mathbf{r}_i\| \|\mathbf{w}_j\|}.$$

Los elementos de la diagonal corresponden normalmente a pares positivos y el resto actúa como negativos. La *loss* aumenta la similitud de los positivos y reduce la de los negativos.

Una dificultad aparece cuando una misma palabra se repite dentro del lote. Dos segmentos asociados a la palabra *the*, por ejemplo, no deberían considerarse negativos entre sí. Las variantes de SigLIP utilizadas en decodificación de palabras introducen máscaras para evitar que las repeticiones se penalicen incorrectamente [63, 10].

El aprendizaje contrastivo presenta varias ventajas. No obliga a utilizar una capa de clasificación con un tamaño fijo, incorpora relaciones entre palabras y permite reutilizar representaciones lingüísticas preentrenadas. Igualmente favorece el aprendizaje de una geometría común entre dos dominios muy diferentes: la señal cerebral y el lenguaje.

Sin embargo, la elección de negativos afecta considerablemente al entrenamiento. Si los negativos son demasiado fáciles, el modelo puede aprender diferencias generales sin distinguir palabras parecidas. Si contienen falsos negativos, se penalizan relaciones válidas. El tamaño del lote, la temperatura de la similitud y el equilibrio de clases también influyen en el resultado.

El contexto se incorpora antes de aplicar la *loss*. Cada ventana cerebral se codifica localmente y las representaciones de varias palabras consecutivas se introducen en un Transformer bidireccional. La salida correspondiente a cada posición contiene información de toda la secuencia. Después, cada una se compara con el *embedding* lingüístico de su palabra. De este modo, el modelo aprende simultáneamente relaciones neuronales entre ventanas y relaciones semánticas entre palabras.

2.5.3. Evaluación de la clasificación de palabras

La evaluación de un clasificador de palabras debe reflejar la dificultad del vocabulario y su distribución. La precisión Top-1 considera correcta una muestra únicamente cuando la palabra real ocupa la primera posición. La precisión Top- k considera correcta la muestra si la palabra aparece entre las k predicciones con mayor puntuación. En señales cerebrales, donde existe una incertidumbre elevada, Top-5 o Top-10 permiten medir si el modelo recupera un conjunto reducido de candidatos plausibles.

Si el vocabulario contiene V palabras y todas las clases tienen la misma probabilidad, el nivel de azar para Top- k es aproximadamente

$$\text{Azar}_{\text{Top-}k} = \frac{k}{V}.$$

Por ejemplo, con 250 palabras, la probabilidad aleatoria de incluir la palabra correcta entre diez candidatos es $10/250 = 0,04$. Esta referencia debe acompañar siempre a los resultados, aunque una línea base aleatoria basada en la distribución real puede ser más adecuada cuando las clases están desbalanceadas.

La precisión equilibrada calcula primero el rendimiento de cada clase y después obtiene su media [8]. Para Top- k , puede expresarse como

$$\text{BA}_{\text{Top-}k} = \frac{1}{V} \sum_{v=1}^V \frac{\text{aciertos Top-}k \text{ de la clase } v}{\text{número de ejemplos de la clase } v}.$$

Esta métrica evita que las palabras más frecuentes dominen el resultado. Por este motivo, la precisión Top-10 equilibrada se ha convertido en una métrica habitual en clasificación contextual de palabras con MEG [40, 30].

Los resultados deben calcularse sobre datos no utilizados para ajustar el modelo ni seleccionar hiperparámetros. En estudios con varios sujetos es importante aclarar si la evaluación es dependiente o independiente del sujeto. En el primer caso, el modelo ha observado datos de esa persona durante el entrenamiento. En el segundo, se evalúa su capacidad para generalizar a participantes completamente nuevos. Esta segunda condición es más exigente y se aproxima mejor a una aplicación clínica [25, 30].

Además, deben evitarse fugas entre estímulos. Si la misma narración aparece en entrenamiento y prueba para sujetos distintos, el modelo puede reconocer características

del audio, la duración o el orden de las palabras. Una partición rigurosa mantiene el mismo estímulo en una única división. Del mismo modo, las ventanas solapadas de una grabación no deben repartirse entre entrenamiento y prueba [25, 30].

Una evaluación fiable incluye comparaciones con varias líneas base. La primera es el nivel de azar. La segunda puede consistir en sustituir la señal cerebral por ruido aleatorio o permutar las correspondencias entre señal y palabra. Estos controles permiten comprobar si el modelo utiliza realmente información neuronal. Asimismo, es conveniente comparar la arquitectura preentrenada con la misma arquitectura inicializada aleatoriamente. De esta forma se separa el efecto del preentrenamiento del efecto de la capacidad del modelo [25, 30].

La variabilidad entre ejecuciones debe reflejarse mediante varias semillas y medidas de dispersión, como desviación típica o error estándar. Para determinar si una mejora supera el azar se pueden utilizar pruebas de permutación. Cuando se comparan dos modelos sobre los mismos ejemplos, las pruebas deben tener en cuenta que las predicciones no son independientes.

Además del resultado agregado, es útil analizar el rendimiento por frecuencia, categoría gramatical, sujeto y conjunto de datos. Estos análisis pueden revelar que la mejora se concentra en palabras frecuentes o en unos pocos participantes. También permiten estudiar si el contexto beneficia por igual a sustantivos, verbos y palabras funcionales.

Por último, las métricas cambian cuando se pasa de clasificación de palabras a reconstrucción de secuencias. En sistemas *brain-to-text* se utilizan medidas como tasa de error de palabra, tasa de error de carácter, BLEU, ROUGE o similitud semántica. Estas métricas evalúan la secuencia completa y pueden incorporar un modelo de lenguaje para reordenar o completar candidatos. Sin embargo, un buen resultado de secuencia no demuestra por sí solo que la señal cerebral sea informativa, ya que el modelo lingüístico puede corregir gran parte de la salida. Por ello, incluso en sistemas completos, siguen siendo necesarios controles con ruido, permutaciones y evaluación directa de la clasificación neuronal [28].

En conjunto, la clasificación contextual de palabras proporciona un marco controlado para estudiar la transferencia de representaciones entre MEG y EEG. Permite mantener una tarea, un espacio lingüístico y unas métricas comunes mientras se modifican la modalidad, el preprocesamiento, la frecuencia de muestreo, el tokenizer o la estrategia de inicialización. Esta separación facilita identificar qué componentes contribuyen realmente a la adaptación y qué limitaciones proceden de la calidad y cantidad de los datos.

2.6 Estado del arte

La decodificación no invasiva del lenguaje reúne tareas que no son directamente equivalentes. Clasificar unas pocas vocales imaginadas, identificar un fragmento de audio entre candidatos, recuperar una palabra dentro de un vocabulario cerrado y generar texto continuo difieren en el espacio de salida, la alineación temporal, la modalidad de registro y el peso que puede tener un modelo lingüístico externo. Por ello, las métricas publicadas solo deben compararse cuando la tarea, los datos, el vocabulario y el protocolo de evaluación son equivalentes. La Tabla 2.3 resume los trabajos más próximos al problema de este TFM: evaluar si las representaciones aprendidas por MEG-XL mediante preentrenamiento de contexto largo en MEG pueden transferirse a EEG y mejorar la clasificación contextual de palabras frente a la misma arquitectura entrenada desde cero.

Tabla 2.3: Comparación de trabajos relevantes en decodificación no invasiva del lenguaje.

Trabajo	Modalidad y tarea	Datos	Método	Resultado principal	Limitación o relevancia
Wang y Ji [55]	EEG durante lectura natural; reconstrucción EEG-texto	ZuCo	Codificación EEG conectada con BART	Generación de secuencias a partir de representaciones EEG	La evaluación posterior mostró el efecto del <i>teacher forcing</i> [32]
d'Ascoli et al. [10]	EEG y MEG; clasificación contextual de palabras	Múltiples datasets de lectura y escucha	Codificador convolucional, Transformer contextual y objetivos lingüísticos T5	Mejora al incorporar contexto neuronal	Entrenamiento supervisado y necesidad de una cantidad considerable de datos
Jayalath et al. [28]	EEG y MEG; clasificación de palabras y reconstrucción de texto	Combinación selectiva de datasets	D-SigLIP, agrupación de datasets y rescoring mediante un modelo de lenguaje	Mejora mediante <i>pooling</i> y modelado lingüístico contextual	Dependencia inicial de un vocabulario de recuperación y del rendimiento del codificador neuronal
BrainOmni [59]	EEG y MEG; múltiples tareas	Corpus multimodal de gran escala	Tokenización común y modelado multimodal	Aprendizaje de representaciones compartidas entre modalidades y montajes	No evalúa específicamente la clasificación contextual de palabras ni la transferencia de contexto largo MEG hacia EEG
MEG-XL [30]	MEG; preentrenamiento autosupervizado de contexto largo y ajuste para clasificación de palabras	Aprox. 300 h de MEG	BioCodec, predicción enmascarada y Transformer <i>criss-cross</i>	Mejor transferencia cuando existen pocos datos del sujeto objetivo	No se ha evaluado el modelo sobre EEG

2.6.1. Decodificación mediante EEG

Una parte importante de la literatura EEG procede del habla imaginada. Estos estudios muestran que vocabularios pequeños, como vocales, sílabas o comandos direccionales, pueden clasificarse en condiciones controladas mediante características temporales, espectrales o redes neuronales, pero el rendimiento suele depender del sujeto, la sesión y el protocolo [42, 2, 49, 45]. Una precisión elevada con dos, cinco o unas pocas clases no es comparable con recuperar palabras dentro de vocabularios de decenas o cientos de elementos. Estos trabajos son antecedentes relevantes de clasificación EEG, pero no constituyen comparadores directos para una tarea de clasificación contextual de palabras durante lectura o escucha continua.

La lectura natural desplazó el foco hacia señales alineadas con palabras dentro de frases. ZuCo combina EEG de alta densidad y seguimiento ocular, de modo que las fijaciones permiten asociar intervalos de señal con palabras concretas [17, 26]. Sobre este tipo de datos, Wang y Ji plantearon una reconstrucción EEG-texto conectando representaciones EEG con BART [55], y DeWave introdujo una codificación discreta de la señal antes del decodificador lingüístico [18]. Estos trabajos abrieron la vía de la generación de texto desde EEG, pero Jo et al. mostraron que parte de los resultados EEG-to-text dependía de *teacher forcing* y de la capacidad del modelo lingüístico más que de la información neuronal disponible [32]. Esta reevaluación hace necesario distinguir la generación de secuencias de la recuperación directa de palabras a partir de señal cerebral.

La cantidad de datos por participante también condiciona los resultados. Sato et al. estudiaron EEG de larga duración durante habla producida y mostraron que aumentar de forma sustancial la profundidad de datos mejora la recuperación de segmentos [47]. Sin embargo, se trata de habla pronunciada y de segmentos temporales, no de lectura silenciosa palabra a palabra; por tanto, sus métricas no deben compararse directamente con la clasificación de palabras percibidas o leídas. En el extremo más cercano al presente TFM se sitúa d'Ascoli et al., que define una tarea de clasificación contextual de palabras aplicable a EEG y MEG mediante ventanas alineadas con palabras, representaciones T5 y contexto neuronal [10]. Entre sus datos EEG se encuentra el conjunto de Broderick et al., distribuido como OpenNeuro ds004408, que registra EEG durante escucha narrativa continua y contiene alineaciones lingüísticas útiles para formular una evaluación palabra a palabra [7].

Jayalath et al. parten de esa formulación y estudian la combinación selectiva de datos heterogéneos de EEG y MEG para mejorar tanto la clasificación de palabras como la reconstrucción de secuencias [28]. Su relevancia para este trabajo no reside en proporcionar una transcripción abierta de ds004408, sino en mostrar que el *pooling* entre datasets y el modelado lingüístico contextual pueden mejorar un sistema cuyo primer paso sigue siendo un codificador neuronal de vocabulario cerrado. En consecuencia, ds004408 es un comparador mucho más próximo al experimento de este trabajo que la clasificación de unas pocas vocales imaginadas: permite evaluar clasificación de palabras durante escucha continua con EEG y se aproxima a la tarea supervisada utilizada para medir la transferencia de MEG-XL.

2.6.2. Decodificación mediante MEG

La MEG ha sido menos accesible que EEG, pero su menor distorsión espacial y su alta resolución temporal han favorecido experimentos de lenguaje continuo [24, 22]. Los trabajos con vocabularios pequeños, como la clasificación de frases imaginadas o pronunciadas, indican que la señal MEG contiene información discriminativa sobre el habla, aunque sus resultados no son extrapolables a transcripción natural [12]. Un cambio más

relevante para la literatura reciente fue el uso de objetivos contrastivos: Défossez et al. acercaron segmentos M/EEG a representaciones de audio escuchado y mostraron que los modelos de audio preentrenados proporcionan objetivos útiles para percepción del habla, aunque el sistema recupera fragmentos de audio candidatos y no palabras ni texto abierto [13].

La publicación de datasets de escucha continua permitió estudiar modelos más contextuales. Armeni et al., MEG-MASC y LibriBrain proporcionan registros de habla natural con anotaciones temporales que han servido como base para tareas de recuperación de audio, clasificación de palabras y ajuste de modelos de contexto [3, 23, 40]. Sobre esta base, d’Ascoli et al. formalizan la clasificación contextual de palabras y Jayalath et al. amplían el sistema hacia reconstrucción *brain-to-text* mediante rescoring lingüístico [10, 28]. Otros resultados recientes, como Brain2Qwerty, muestran reconstrucción no invasiva de frases mecanografiadas, pero la tarea contiene información motora de pulsación y no es comparable con la percepción o lectura de palabras [35].

2.6.3. Modelos preentrenados de señales cerebrales

Los modelos fundacionales de EEG intentan aprender representaciones reutilizables mediante objetivos autosupervisados. LaBraM y EEGPT aplican preentrenamiento tipo Transformer sobre grandes colecciones EEG y muestran transferencia en tareas principalmente clínicas o BCI generales, no específicamente en lenguaje continuo [31, 53]. CBraMod introduce atención *criss-cross* para separar relaciones temporales y espaciales en EEG, lo que lo acerca arquitectónicamente a MEG-XL, aunque sus ventanas de preentrenamiento son más cortas y su evaluación no se centra en clasificación contextual de palabras [54].

Otra línea aprende tokens discretos de la señal. BioCodec adapta códecs neuronales a bioseñales y permite usar códigos cuantizados como representación intermedia o como objetivo de predicción enmascarada [4]. BrainOmni aborda de forma explícita la heterogeneidad entre EEG y MEG mediante tokenización común y modelado multimodal, por lo que constituye un antecedente directo de la transferencia entre montajes y modalidades [59]. No obstante, su objetivo es generalista y no responde a la pregunta específica de si un modelo MEG de contexto largo mejora la clasificación contextual de palabras al transferirse a EEG. En la misma línea de escalado autosupervisado, *The Brain’s Bitter Lesson* apoya el uso de grandes corpus no etiquetados antes del ajuste fino, pero no resuelve por sí mismo la transferencia MEG-EEG en vocabularios de palabras [29].

MEG-XL combina varios de estos elementos en el antecedente más cercano al presente trabajo. Preentrena con aproximadamente 300 horas de MEG, tokeniza la señal con BioCodec, utiliza predicción enmascarada y modela fragmentos continuos largos mediante un Transformer *criss-cross* [30]. Después se ajusta a clasificación de palabras siguiendo la formulación de d’Ascoli et al. Sus resultados indican que el preentrenamiento de contexto largo es especialmente útil cuando hay pocos datos del sujeto objetivo y que no basta con proporcionar contexto largo durante el ajuste: el modelo debe haber aprendido previamente a utilizarlo. Sin embargo, todo ese ciclo se evalúa con MEG. Aunque BioCodec se entrenó originalmente con EEG, las representaciones contextuales de MEG-XL no han sido evaluadas sobre señales EEG.

2.6.4. Limitaciones de los trabajos existentes

La primera limitación común es la heterogeneidad de tareas. Habla imaginada, habla producida, escucha, lectura natural, recuperación de audio, clasificación de palabras y

generación de texto miden capacidades distintas. La actividad registrada durante habla producida o escritura contiene componentes motores que no aparecen durante escucha o lectura silenciosa; la lectura natural requiere seguimiento ocular y produce fijaciones variables; y la generación de texto puede beneficiarse de un modelo lingüístico incluso cuando la señal cerebral aporta poca información [17, 26, 32]. Por ello, el presente trabajo se centra en una tarea intermedia y controlada: recuperación de palabras a partir de ventanas EEG alineadas con eventos lingüísticos.

La segunda limitación es la cantidad y distribución de los datos. Los conjuntos profundos muestran que añadir horas por participante mejora la decodificación, pero registrar muchas horas para cada nuevo usuario no es una solución práctica [47, 40, 10]. Los modelos preentrenados buscan reducir esa dependencia, aunque sus ventajas deben compararse frente a la misma arquitectura inicializada aleatoriamente. Esta comparación es especialmente importante cuando se cambia de modalidad, porque EEG y MEG difieren en geometría, referencia, amplitud, ruido y relación entre sensores y fuentes cerebrales.

La tercera limitación es la transferencia entre dominios. Los *embeddings* de posición, las máscaras de sensores y la atención espacial ayudan a combinar montajes diferentes, pero no garantizan que una representación aprendida en MEG conserve información útil en EEG. BrainOmni estudia una representación común EEG-MEG y Jayalath et al. muestran el valor del *pooling* entre datasets en sistemas de clasificación y reconstrucción, pero todavía no se ha determinado si las representaciones aprendidas mediante el preentrenamiento de contexto largo de MEG-XL pueden transferirse a EEG y mejorar la clasificación contextual de palabras frente a la misma arquitectura entrenada desde cero [59, 28, 30].

Por último, el vocabulario cerrado y la evaluación siguen siendo restricciones necesarias. La recuperación sobre decenas o cientos de palabras no equivale a una comunicación abierta, y los mecanismos de rescoring o rellenado mediante modelos de lenguaje pueden ocultar errores del codificador cerebral [28]. Antes de avanzar hacia generación abierta resulta necesario demostrar que la mejora procede de la señal neuronal. De ahí que este TFM compare inicialización preentrenada y aleatoria dentro de una misma arquitectura y sobre una tarea EEG de clasificación contextual de palabras.

CAPÍTULO 3

Datasets utilizados

Como se ha descrito anteriormente, una de las limitaciones de la decodificación cerebral no invasiva es la disponibilidad de datos. La adquisición de EEG y sobre todo de MEG requiere equipamiento especializado, tiempo de preparación y la participación de voluntarios en sesiones que pueden resultar largas. Además, los conjuntos de datos disponibles presentan diferencias importantes en el número y la posición de los sensores, la frecuencia de muestreo, el idioma, la tarea realizada y la cantidad de información disponible por participante.

En este trabajo era necesario combinar varios conjuntos de datos para aumentar la cantidad y la diversidad de registros disponibles. No obstante, diferentes datasets desempeñan distintas funciones dentro del proceso experimental. Los conjuntos de lectura y escucha se emplean para entrenar la adaptación de MEG-XL a esta nueva modalidad. Finalmente, OpenNeuro ds004408 se reserva para realizar el *fine-tuning* supervisado y evaluar la clasificación de palabras durante la escucha de habla continua.

Los cuatro conjuntos utilizados en entrenamiento se dividen en dos grupos en función de la tarea realizada. En primer lugar se incorporan los conjuntos de lectura: ZucCo 2.0 y el de Nieuwland et al. Posteriormente se introducen los conjuntos de escucha: SparrKULee y OpenNeuro ds007808. La adaptación comienza por lectura porque ofrece condiciones de experimentación relativamente controladas y permite realizar un primer entrenamiento con EEG relacionado con procesamiento lingüístico. Después se aproxima el dominio de entrenamiento a la tarea final mediante registros obtenidos durante la percepción auditiva del habla.

A pesar de las diferencias entre ellos, todos estos conjuntos se transforman a una interfaz común. Se conservan únicamente los canales EEG, junto con sus posiciones y una máscara para que el modelo tenga un único número de sensores de entrada, de forma que se enmascaran los sensores que no están presentes en un conjunto concreto. La señal se filtra inicialmente en su frecuencia de muestreo original y después se remuestrea a 50 Hz – al igual que en MEG-XL. A partir de cada grabación se extraen ventanas completas y no solapadas de 150 segundos. Los fragmentos finales que no alcanzan esta duración se descartan.

Durante esta etapa no se entrena utilizando ni las palabras, ni las transcripciones, ni las alineaciones lingüísticas como etiquetas. BioCodec transforma la señal en una secuencia discreta de códigos neuronales y el modelo aprende a reconstruir los códigos que han sido ocultados. De esta forma, los conjuntos de entrenamiento pueden combinarse aunque estén asociados a idiomas y paradigmas experimentales diferentes. Esto se hace para que el modelo aprenda regularidades temporales y espaciales de la señal EEG que puedan transferirse posteriormente a una tarea supervisada.

3.1 Selección de conjuntos de entrenamiento

MEG-XL se preentrena de forma autosupervisada con aproximadamente 300 horas de MEG procedentes de CamCAN, MOUS y SMN4Lang [30]. Estos conjuntos incluyen diferentes participantes, idiomas y tareas. Posteriormente, el modelo se ajusta y evalúa sobre conjuntos de escucha continua, como MEG-MASC, Armeni et al. y LibriBrain [23, 3, 40], tal como se resume en la Tabla 3.1.

Dataset	Tipo	Tarea	Idioma	Sujetos	Sensores	Duración	Uso en MEG-XL
CamCAN	MEG	Reposo y tarea sensoriomotora	No aplica	~700	306	~160 h	Preentrenamiento
MOUS	MEG	Escucha de oraciones	Neerlandés	104	275	~81 h	Preentrenamiento
SMN4Lang	MEG	Escucha de habla natural	Mandarín	12	306	~72 h	Preentrenamiento
MEG-MASC	MEG	Escucha de historias	Inglés	27	208	54 h	Ajuste y evaluación
Armeni et al.	MEG	Escucha de audiolibros	Inglés	3	269	30 h	Ajuste y evaluación
LibriBrain	MEG	Escucha de audiolibros	Inglés	1	306	52,32 h	Ajuste y evaluación

Tabla 3.1: Conjuntos de datos utilizados para el preentrenamiento y la evaluación de MEG-XL.

Para adaptar este procedimiento a EEG se buscaron conjuntos de lectura o escucha con señal suficientemente continua para extraer ventanas de 150 segundos. Se descartaron datasets formados únicamente por palabras o frases aisladas, aquellos que no proporcionaban la señal EEG completa y las tareas de producción oral, debido a la posible presencia de artefactos musculares. Se vio la necesidad de incluir datasets de lectura debido a la falta de conjuntos de escucha continua con un número suficiente de horas de entrenamiento. También se revisó la lateralidad de los participantes, priorizando sujetos diestros cuando esta información estaba disponible. Finalmente, se seleccionaron ZuCo 2.0 y Nieuwland et al. para lectura, y SparrKULee y OpenNeuro ds007808 para escucha. OpenNeuro ds004408 se mantiene separado de esta fase y se utiliza únicamente en el ajuste supervisado.

3.2 Datasets de entrenamiento

3.2.1. Datasets de lectura

ZuCo 2.0

ZuCO 2.0 es un conjunto de EEG y seguimiento ocular simultáneo registrado durante la lectura de frases en inglés [26]. Participaron 18 personas, que leyeron un total de 739 frases. De estas, 349 pertenecen a una tarea de lectura natural y 390 a una tarea de anotación en la que los participantes debían buscar relaciones semánticas concretas.

La señal se adquirió mediante un sistema de 128 electrodos a 500 Hz. Tras eliminar los canales utilizados para registrar actividad ocular, facial y del cuello, el conjunto proporciona 105 canales EEG. La adquisición simultánea de la mirada permite conocer qué palabra estaba observando el participante y durante cuánto tiempo. Esto resulta especialmente importante en lectura natural, porque las palabras no se muestran durante intervalos fijos, ya que cada persona puede detenerse, saltar una palabra o volver a una parte anterior de la frase.

En este trabajo se utiliza únicamente la tarea de lectura natural, denominada NR. La tarea específica de anotación se descarta porque introduce una búsqueda semántica explícita que modifica el proceso normal de lectura. La copia preprocesada empleada contiene aproximadamente 11.1 horas de señal NR.

La separación entre entrenamiento y validación se realiza por participante. Un 15 % de los sujetos se reserva de forma determinista para validación, utilizando una semilla fija. De esta manera se evita que segmentos de una misma persona aparezcan en ambos subconjuntos.

Nieuwland et al.

El conjunto que proponen Nieuwland et al. procede de un estudio de replicación a gran escala sobre predicción lingüística durante la lectura [38]. El experimento fue realizado de forma coordinada en nueve laboratorios y reunió datos válidos de 334 participantes. Esta distribución multicéntrica convierte al conjunto en uno de los registros EEG de lectura con mayor número de sujetos disponibles públicamente.

Los participantes de este estudio leían frases en inglés presentadas palabra por palabra. El experimento principal, denominado *DeLong*, estudiaba cómo la probabilidad de aparición de una palabra afectaba a la respuesta N400. Cada contexto conducía a sustantivos con distintos grados de predictibilidad y estaba precedido por el artículo correspondiente. El conjunto también incluye una tarea de control formada por frases más breves.

A diferencia de la lectura libre de ZuCo, la presentación visual estaba temporizada. Generalmente cada palabra se mostraba durante 200 ms y era seguida por un intervalo vacío de 300 ms. Esta presentación mantiene una velocidad de dos palabras por segundo y proporciona una referencia temporal común entre participantes.

Por otro lado, al tratarse de un estudio realizado en varios laboratorios, el número de canales, la frecuencia de muestreo y el equipo utilizado no son idénticos en todos los registros. El análisis ERP original redujo los datos a un conjunto común de electrodos para facilitar la comparación entre centros. En este trabajo no se reproduce esa reducción orientada al análisis de la N400. En su lugar se conservan los canales identificados como EEG y se utiliza una máscara de sensores para representar los distintos montajes dentro del mismo modelo.

Se emplean ambas tareas existentes. Las grabaciones se procesan como señal continua, sin proporcionar al modelo la identidad de las palabras ni su probabilidad de cierre. En conjunto, el estudio original aporta alrededor de 170 horas de EEG, aunque la cantidad efectiva utilizable depende de los registros que se encuentran disponibles en un formato compatible.

En este caso la validación vuelve a realizarse por participante. Se reserva un 10 % de los sujetos mediante una división determinista. Esto resulta especialmente importante en un conjunto multicéntrico, ya que obliga al modelo a enfrentarse durante la validación a personas y registros que no ha observado previamente.

3.2.2. Datasets de escucha

SparrKULee

SparrKULee es el primer dataset de escucha continua en el entrenamiento, se trata de un repositorio de respuestas EEG evocadas por habla creado en KU Leuven [1]. Contiene datos de 85 participantes jóvenes, con audición normal y neerlandés o flamenco como

lengua materna. Cada participante escuchó entre 90 y 150 minutos de habla natural, distribuidos en varios bloques de aproximadamente 15 minutos.

La adquisición se realizó con 64 canales EEG mediante un sistema BioSemi ActiveTwo. El conjunto completo reúne alrededor de 168 horas de señal. La mayor parte corresponde a narraciones sin ruido, aunque también algún fragmento de habla presentada en condiciones de ruido. Esta combinación se diseñó para estudiar el seguimiento cortical del habla y para entrenar modelos de codificación, decodificación y correspondencia entre EEG y audio.

En el entrenamiento se selecciona solo la tarea *listeningActive*. Los registros se procesan como secuencias continuas y se transforman a ventanas de 150 segundos. No se utilizan los atributos acústicos calculados por los autores ni las etiquetas de correspondencia entre segmentos.

Para la validación se reservan cinco participantes completos. Esta partición mantiene separados los sujetos de entrenamiento y permite comprobar la capacidad de generalización dentro de un sistema de adquisición homogéneo.

JapanEEG (OpenNeuro ds007808)

OpenNeuro ds007808, también denominado JapanEEG, es un conjunto multimodal de gran escala orientado al estudio del habla [46]. Incluye EEG, electromiografía facial y audio sincronizados de tres hablantes nativos de japonés. Los datos se registraron durante varios meses y mediante tres sistemas de adquisición diferentes, con configuraciones comprendidas entre 62 y 128 canales EEG.

El conjunto al completo supera las 1000 horas pero está dominado por una tarea de producción oral de vocabulario abierto. Por suerte, también contiene tareas de escucha y habla encubierta. Tiene una alta profundidad por participante, lo que permite estudiar variaciones entre sesiones, días y dispositivos que no aparecen en conjuntos más breves.

En este trabajo no se utiliza la tarea de producción oral *speechopen* pese a que representa la mayor parte del conjunto, ya que introduce actividad muscular facial y articular. Además, esta tarea se aleja del objetivo de decodificar palabras percibidas durante la escucha.

De este conjunto se seleccionan las tareas *listening* y *listeningcovert*. La primera contiene aproximadamente 33,8 horas de grabaciones de escucha. La segunda contiene cerca de 167 horas de registros en los que se alternan periodos de escucha y repetición mental. En estos registros se conserva la grabación completa como contexto, pero únicamente los intervalos etiquetados como escucha pueden seleccionarse como objetivo de reconstrucción. Los periodos de habla encubierta ayudan a mantener la continuidad temporal, pero no contribuyen directamente a la pérdida aplicada sobre los tokens enmascarados.

Esta decisión se tomó para aprovechar una parte considerable de las sesiones sin confundir percepción auditiva y producción imaginada. Al mismo tiempo, introduce un conjunto profundo y longitudinal que complementa el mayor número de sujetos de SparrKULee. Las particiones de validación se realizan mediante sesiones completas, de modo que una misma sesión no se divide entre entrenamiento y validación.

3.3 Dataset de fine-tuning

3.3.1. OpenNeuro ds004408

Se ha utilizado OpenNeuro ds004408 como dataset de *fine-tuning*. Este conjunto no se incorpora al entrenamiento autosupervisado continuo, sino que se reserva para la etapa supervisada de clasificación de palabras. De esta manera, el modelo se evalúa sobre registros que no han contribuido previamente a la reconstrucción de códigos neuronales y se evita mezclar datos de preentrenamiento y evaluación final.

OpenNeuro ds004408 contiene respuestas EEG de 19 participantes durante la escucha de habla narrativa continua en inglés. Los registros se adquirieron con 128 canales y se distribuyen en bloques de aproximadamente tres minutos, hasta reunir alrededor de 20,6 horas de señal. El conjunto fue utilizado originalmente para estudiar el seguimiento cortical de información fonética y el procesamiento semántico durante la comprensión de habla natural [16, 7]. Por ello resulta adecuado como conjunto final: comparte el dominio auditivo del objetivo experimental y, al mismo tiempo, cuenta con alineaciones temporales palabra a palabra que permiten formular una tarea supervisada.

En esta fase el dataset se procesa en formato *word-aligned*. Para cada palabra del audiolibro se extrae una ventana EEG de tres segundos alrededor de su inicio temporal, desde 0,5 segundos antes hasta 2,5 segundos después. El tramo previo permite estimar una línea base y conserva el contexto inmediato anterior, mientras que el tramo posterior recoge la respuesta asociada a la percepción y procesamiento de la palabra. Después de la corrección de línea base, la normalización robusta y el recorte de valores extremos, se agrupan 50 palabras consecutivas para formar entradas de 150 segundos. Así se mantiene la longitud temporal utilizada durante el entrenamiento, pero cada subventana queda asociada a una palabra conocida.

Las palabras se representan mediante *embeddings* lingüísticos de T5. El codificador neuronal produce una representación para cada ventana EEG y una proyección aprende a situarla cerca del *embedding* de la palabra correspondiente. El ajuste se realiza con una pérdida contrastiva, que acerca las parejas EEG–palabra correctas y separa las combinaciones incorrectas dentro del lote. Durante la evaluación se plantea una tarea de recuperación: dada una representación EEG alineada con una palabra, se ordenan los candidatos del vocabulario según su similitud y se comprueba si la palabra verdadera aparece entre las primeras posiciones.

La separación de ds004408 respecto al entrenamiento continuo también facilita la comparación con trabajos previos. En particular, en d’Ascoli et al. utilizan este conjunto dentro de una arquitectura de clasificación contextual de palabras y establecen métricas de recuperación sobre representaciones lingüísticas [11]. Esto permite comparar la adaptación propuesta no solo frente a una inicialización desde cero, sino también frente a referencias publicadas que trabajan sobre el mismo tipo de señal y tarea.

De esta forma, ds004408 cumple 2 funciones: actúa como conjunto supervisado para especializar el modelo en recuperación de palabras y proporciona un punto de comparación cuantitativa con el estado del arte. La decisión de reservarlo exclusivamente para *fine-tuning* hace que cualquier mejora pueda atribuirse a la transferencia desde las etapas previas y no a una exposición autosupervisada al mismo registro.

3.4 Tabla resumen

La Tabla 3.2 resume las principales características de los conjuntos descritos y la función que desempeña cada uno dentro del trabajo.

Dataset	Tipo	Tarea	Idioma	Sujetos	Sensores	Duración	Uso
ZuCo 2.0	EEG	Lectura natural	Inglés	18	105	11,1 h NR	Training
Nieuwland et al.	EEG	Lectura temporizada	Inglés	334	≥ 32	~ 170 h	Training
SparrKULee	EEG	Escucha	Neerlandés	85	64	168 h	Training
OpenNeuro ds007808	EEG	Escucha	Japonés	3	62–128	33,8 h (+167,0 h)	Training
OpenNeuro ds004408	EEG	Escucha	Inglés	19	128	20,6 h	Fine-tuning

Tabla 3.2: Resumen de los conjuntos de datos utilizados y su función dentro del proceso experimental. En ds007808, las horas de *listeningcovert* corresponden a grabaciones completas utilizadas como contexto y no a 167 horas de objetivos exclusivamente auditivos.

CAPÍTULO 4

Adaptación de MEG-XL a “EEG-XL”

4.1 Descripción general de la propuesta

Como se ha ido comentando a lo largo de los anteriores capítulos, la propuesta de este trabajo consiste en adaptar MEG-XL a registros EEG. La idea es mantener, dentro de lo que sea posible, aquello que hace valioso al modelo original, como por ejemplo el aprendizaje autosupervisado con contexto largo. MEG-XL no se limita a procesar ventanas breves alineadas con palabras, sino que aprende representaciones a partir de fragmentos continuos de dos minutos y medio. Esta propiedad resulta especialmente interesante para EEG, donde la señal es más ruidosa y la información lingüística puede aparecer distribuida en patrones débiles a lo largo del tiempo.

La Figura 4.1 resume el flujo original de MEG-XL que se toma como punto de partida: primero un preentrenamiento autosupervisado sobre señal MEG continua y después un ajuste fino supervisado para clasificación contextual de palabras.




Figura 4.1: Resumen del preentrenamiento y del ajuste fino de MEG-XL. El modelo aprende primero a reconstruir tokens cerebrales en contextos largos y posteriormente reutiliza esas representaciones en una tarea contrastiva de clasificación contextual de palabras. Adaptado conceptualmente de Jayalath y Parker Jones.

Esta adaptación se puede entender como un cambio de dominio. El modelo de partida fue entrenado con MEG, utilizando sensores magnéticos, geometrías específicas y una relación señal-ruido distinta. En EEG cambian la magnitud física, la referencia, la disposición de los sensores, el número de canales y los artefactos más frecuentes. Por tanto, es necesario construir una interfaz común que permita representar diferentes montajes EEG dentro de la misma arquitectura.

El entrenamiento final lanzado en este trabajo corresponde a un preentrenamiento continuo en dos etapas. Primero se utilizan datasets de lectura y después datasets de escucha. La etapa de lectura sirve como una adaptación inicial a EEG lingüístico en con-

diciones más controladas. La etapa de escucha aproxima el modelo al dominio final, que es la clasificación de palabras durante percepción auditiva continua.

Además, el experimento compara tres variantes preentrenadas y un control supervisado directo. Una variante aprende el currículo EEG desde una inicialización aleatoria. Las otras dos parten del checkpoint de MEG-XL y se diferencian únicamente en la forma de representar el tipo de sensor: una utiliza un embedding específico de EEG inicializado a partir del embedding de magnetómetro, y la otra reutiliza directamente el embedding de magnetómetro para los canales EEG. Las tres variantes preentrenadas siguen exactamente el mismo orden, lectura seguida de escucha, de modo que la comparación permite estudiar por separado el efecto del preentrenamiento EEG, de la transferencia desde MEG y de la elección del embedding de tipo de sensor.

La propuesta final se puede resumir en una arquitectura que recoge cuatro decisiones de MEG-XL:

- utilizar ventanas continuas de 150 segundos;
- filtrar inicialmente la señal entre 0,1 y 40 Hz en la frecuencia de muestreo original y remuestrearla después a 50 Hz, de modo que la banda representada en la entrada final queda limitada por la frecuencia de Nyquist final;
- tokenizar cada canal con BioCodec y entrenar mediante predicción de tokens enmascarados;
- realizar el entrenamiento en dos fases, primero lectura y después escucha, comparando inicialización aleatoria, transferencia desde MEG-XL con embedding EEG y transferencia desde MEG-XL con embedding MEG.

De esta forma, la parte supervisada de clasificación de palabras queda separada del preentrenamiento, como sucede con MEG-XL. Los cuatro datasets descritos en el capítulo anterior se utilizan para intentar aprender una representación “general” de EEG. Posteriormente, ds004408 permite ajustar esa representación a una tarea *word-aligned* concreta, con ventanas asociadas al inicio de cada palabra y evaluación mediante recuperación de embeddings lingüísticos.

La Figura 4.2 muestra cómo se materializa esta comparación experimental en EEG-XL, separando el preentrenamiento EEG desde cero, las dos variantes de transferencia desde MEG-XL y el control supervisado directo.

4.2 Preprocesamiento del EEG

4.2.1. Preprocesado de la señal

Todos los datasets de entrenamiento se transforman a una frecuencia de muestreo común de 50 Hz tal y como lo hace MEG-XL. Esta elección reduce el coste computacional de las ventanas largas. Un segmento de 150 segundos contiene 7500 muestras por canal antes de la tokenización, por lo que aumentar la frecuencia de muestreo incrementaría de forma directa la memoria necesaria y el número de tokens que debe procesar el Transformer.

El entrenamiento realizado aplica primero un filtrado paso banda de 0,1–40 Hz sobre la señal en su frecuencia de muestreo original y, posteriormente, remuestrea todos los registros a 50 Hz. Como la frecuencia de Nyquist de una señal muestreada a 50 Hz es 25 Hz, la entrada final del modelo no debe interpretarse como una representación completa de




Figura 4.2: Diseño experimental de la adaptación de MEG-XL a EEG-XL. Las tres rutas autosupervisadas mantienen el mismo currículum de lectura-escucha y difieren en la inicialización y en el embedding de tipo de sensor; el control supervisado permite separar el efecto del preentrenamiento EEG de la evaluación directa sobre ds004408.

la banda 0,1–40 Hz. En la práctica, durante el remuestreo se aplica el filtrado antialiasing necesario, por lo que las componentes superiores a la frecuencia de Nyquist final quedan atenuadas o eliminadas. Por tanto, aunque el preprocesamiento inicial utiliza un límite superior de 40 Hz, la banda efectiva disponible para el modelo tras el remuestreo queda limitada aproximadamente a 0,1–25 Hz.

Se mantiene la frecuencia final de 50 Hz por compatibilidad con la configuración original de MEG-XL y por coste computacional. En ventanas de 150 segundos, esta frecuencia produce 7500 muestras por canal antes de la tokenización. Aumentar la frecuencia de muestreo incrementaría directamente la longitud temporal, el número de tokens y el consumo de memoria del Transformer, dificultando el entrenamiento con contextos largos.

Después del filtrado y el remuestreo, cada grabación se divide en ventanas completas de 150 segundos. Para montar estas ventanas se utilizan segmentos continuos y no solapados dentro de cada registro. Los fragmentos finales que no alcanzan la duración requerida se descartan. Esta decisión evita introducir relleno artificial, repetir muestras para completar una ventana o unir partes de la señal que no son contiguas, lo que podría introducir artefactos y sesgos en el entrenamiento.

A partir de cada ventana de 150 segundos, se subdivide la señal en bloques de tres segundos. Esta subdivisión mantiene la escala temporal utilizada por MEG-XL y coincide con la duración de las ventanas que más tarde se utilizan en clasificación de palabras. Durante el preentrenamiento continuo, esos bloques no se asocian a palabras concretas; funcionan como unidades temporales sobre las que se puede aplicar el enmascaramiento.

La normalización se aplica para reducir diferencias de escala entre canales, sesiones y datasets. Este paso es de vital importancia en EEG porque cada conjunto puede haber sido registrado con amplificadores, referencias y montajes distintos. La normalización no

elimina por completo estas diferencias, pero evita que el modelo dependa de magnitudes absolutas que no son comparables entre datasets.

Siguiendo el ejemplo de MEG-XL, se ha creado una interfaz común para cargar los datasets. Cada ejemplo contiene la señal EEG, las posiciones de los sensores y una máscara que indica qué canales son reales. Cuando un conjunto tiene menos sensores que otro, no se fuerza una interpolación espacial previa; se representa dentro de una dimensión común y se enmascaran los canales ausentes. Así, el modelo puede entrenar con diferentes montajes sin confundir sensores inexistentes con señales de valor cero.




Figura 4.3: Preprocesamiento EEG: filtrado, remuestreo, normalización, ventanas, montaje común y máscaras.

4.2.2. Alineamiento con las palabras

El entrenamiento autosupervisado final no utiliza palabras, transcripciones ni alineaciones lingüísticas como etiquetas. Durante las etapas de lectura y escucha, el modelo recibe EEG continuo y aprende a reconstruir códigos neuronales ocultos. Por tanto, pueden combinarse datasets con idiomas y paradigmas diferentes sin construir un vocabulario común.

En los conjuntos de lectura, las anotaciones de presentación visual o fijación sirven para seleccionar tareas relacionadas con procesamiento lingüístico, pero no se utilizan como objetivo de entrenamiento. En ZuCo se emplea la tarea de lectura natural, y en el conjunto de Nieuwland et al. las tareas *delong* y *control*. En los conjuntos de escucha, se seleccionan tareas de percepción auditiva continua. En OpenNeuro ds007808, los registros *listeningcovert* se tratan con cuidado: la grabación completa puede proporcionar contexto, pero solo los intervalos etiquetados como escucha son candidatos para ser enmascarados y reconstruidos.

El alineamiento palabra a palabra aparece después, en la etapa de *fine-tuning* con OpenNeuro ds004408. En ese caso sí se extraen ventanas de tres segundos alrededor del inicio de cada palabra y se agrupan 50 palabras consecutivas para formar una entrada de 150 segundos. De esta forma primero el modelo aprende regularidades generales de EEG continuo y después ya se especializa en recuperación de palabras.

4.3 Adaptación de la arquitectura MEG-XL

4.3.1. Componentes conservados

La adaptación final mantiene la arquitectura principal de MEG-XL. La señal se tokeniza con BioCodec, que transforma cada canal en una secuencia discreta de códigos mediante cuantización vectorial residual. En la configuración utilizada, BioCodec emplea un vocabulario de 256 códigos, seis cuantizadores y un factor de reducción temporal de 12. De esta forma, los 7500 puntos temporales de una ventana de 150 segundos a 50 Hz se convierten en una secuencia de tokens más corta, manejable por el Transformer.

Sobre esos tokens se aplica el Transformer con una combinación de 2 tipos de atención que se llama atención cruzada *criss-cross*. La atención temporal permite relacionar momentos dentro de un mismo sensor, mientras que la atención espacial combina información entre sensores para un mismo instante. Esta factorización conserva la idea original de MEG-XL: modelar dependencias largas sin construir una atención completa sobre todos los pares canal-tiempo.

También se conserva el objetivo autosupervisado. El modelo oculta bloques temporales y debe predecir los códigos de BioCodec correspondientes a esas posiciones. La *loss* es una entropía cruzada sobre los códigos discretos de los cuantizadores. En el entrenamiento se enmascaran subsegmentos de tres segundos, de forma que el modelo no puede resolver la tarea únicamente interpolando muestras vecinas inmediatas y fuerza al Transformer a aprender patrones más amplios de la señal.

Por tanto, la contribución de la adaptación está en hacer que la misma arquitectura pueda recibir EEG heterogéneo y en definir un curriculum de entrenamiento adecuado para pasar de lectura a escucha. La arquitectura, el tokenizer y el objetivo autosupervisado se mantienen lo más cerca posible de MEG-XL, mientras que los cambios se concentran en la entrada EEG, las máscaras de sensores, la selección de datasets y el entrenamiento por etapas.

4.3.2. Cambios para trabajar con canales EEG

MEG-XL fue diseñado para trabajar con magnetómetros y gradiómetros. En EEG solo existe un tipo de sensor dentro del experimento, pero los montajes varían mucho entre datasets. Por ello se introduce el tipo de sensor EEG dentro del espacio de tipos ya utilizado por la arquitectura. La configuración final mantiene tres tipos posibles: gradiómetro, magnetómetro y EEG. En los datos de este trabajo todos los canales reales pertenecen al tipo EEG, pero conservar los otros tipos permite cargar parcialmente los pesos de MEG-XL sin rediseñar el modelo.

La posición de cada electrodo se utiliza como información espacial al no tener el índice de un canal el mismo significado en todos los conjuntos. Un canal situado en una región frontal no debería tratarse como equivalente a otro canal occipital solo porque ocupa la misma posición en una matriz. Al proporcionar coordenadas y máscaras de sensores, el modelo puede aprender relaciones espaciales en función de la geometría real disponible en cada registro.

Formalmente, si el canal c tiene coordenadas normalizadas $\mathbf{p}_c = (x_c, y_c, z_c) \in \mathbb{R}^3$ y tipo de sensor $s_c \in \{0, 1, 2\}$, con 0 para gradiómetro, 1 para magnetómetro y 2 para EEG, la información espacial se introduce mediante un *embedding* Fourier gaussiano:

$$\phi(\mathbf{p}_c) = [\sin(2\pi\mathbf{p}_c\mathbf{B}), \cos(2\pi\mathbf{p}_c\mathbf{B})], \quad \mathbf{B}_{ij} \sim \mathcal{N}(0, \sigma^2), \quad (4.1)$$

donde $\mathbf{B} \in \mathbb{R}^{3 \times d_F/2}$ es una matriz de frecuencias fija. Este vector se proyecta a la dimensión latente del modelo:

$$\mathbf{e}_c^{\text{pos}} = \mathbf{W}_{\text{pos}} \phi(\mathbf{p}_c) + \mathbf{b}_{\text{pos}}. \quad (4.2)$$

El tipo de sensor se representa mediante una tabla aprendida $\mathbf{E}_{\text{type}} \in \mathbb{R}^{3 \times d}$:

$$\mathbf{e}_c^{\text{type}} = \mathbf{E}_{\text{type}}[s_c]. \quad (4.3)$$

Por tanto, para el token temporal τ del canal c , el vector de entrada al Transformer queda:

$$\mathbf{h}_{c,\tau}^{(0)} = \mathbf{e}_{c,\tau}^{\text{tok}} + \mathbf{e}_c^{\text{pos}} + \mathbf{e}_c^{\text{type}}. \quad (4.4)$$

En la configuración base de EEG se usa $s_c = 2$ para todos los canales reales. La posición distingue electrodos dentro de un mismo montaje y el tipo de sensor permite mantener la compatibilidad con los pesos de MEG-XL sin confundir la modalidad física de la señal. En la variante de transferencia con embedding MEG, la señal sigue tratándose como EEG en posiciones, máscaras y orientación, pero la consulta a la tabla de tipos reutiliza la fila de magnetómetro aprendida por MEG-XL. Así se puede aislar el efecto de introducir un embedding EEG específico frente a reutilizar directamente el embedding MEG disponible.

Otra diferencia con respecto a MEG-XL es el tamaño de nuestro modelo debido al número de canales máximo de los datasets. Nuestros datos de EEG contienen montajes de 64, 105, 128 o configuraciones variables según el laboratorio y la sesión. La dimensión máxima de canales se infiere a partir de los datasets disponibles y a cada uno se le aplica una máscara. Esta máscara se aplica tanto durante el procesamiento como en el cálculo de la pérdida, evitando que los canales añadidos para igualar dimensiones modifiquen canales entrenados.

Tabla 4.1: Resumen de la arquitectura y número de parámetros del modelo EEG.

N.	Componente	Tipo	Parámetros
0	tokenizer	BioCodecTokenizerAdapter	3,2 M
1	rvq_projector	Linear	49,7 K
2	position_fourier_emb	GaussianFourierEmb3D	375
3	position_projector	Linear	128 K
4	orientation_fourier_emb	GaussianFourierEmb3D	375
5	orientation_projector	Linear	128 K
6	sensor_type_layer	Embedding	1,5 K
7	criss_cross_transformer	SpatialTemporalEncoder	21,0 M
8	output_head	Linear	787 K
Parámetros entrenables			22,1 M
Parámetros no entrenables			3,2 M
Parámetros totales			25,3 M

Dos experimentos utilizan como base el modelo preentrenado con MEG de MEG-XL. En ambos casos, el modelo se carga en la nueva arquitectura de forma parcial. Los pesos compatibles, como los del Transformer y gran parte de las proyecciones internas, pueden reutilizarse. Los componentes que dependen de la nueva configuración EEG o que dejan de encajar exactamente se inicializan de nuevo. La diferencia entre ambas variantes está en la fila de embedding de tipo de sensor empleada para los canales EEG: una introduce

un embedding EEG específico y la otra reutiliza el embedding de magnetómetro. De esta forma, la carga parcial permite estudiar la transferencia de MEG a EEG sin forzar una equivalencia falsa entre sensores de diferentes tareas.




Figura 4.4: Arquitectura EEG-XL: BioCodec, códigos RVQ, embeddings, Transformer criss-cross y predicción de tokens enmascarados.

4.3.3. Tokenización de la señal

Durante el desarrollo se contemplaron otros tokenizadores, como BrainOmni o BrainTokenizer, porque están diseñados para representar bioseñales heterogéneas y podrían ser adecuados para combinar modalidades. Sin embargo, finalmente el entrenamiento utiliza BioCodec. Así se mantiene la compatibilidad con MEG-XL y se reduce el número de cambios simultáneos: si se cambiara a la vez la modalidad, el tokenizador y la arquitectura, sería más difícil interpretar el efecto de la transferencia. Por otro lado, es un tokenizador entrenado sobre EEG, por lo que, teóricamente, debería funcionar mejor con nuestro conjunto de datos que con el de MEG-XL.

BioCodec se aplica canal a canal. Cada canal EEG se convierte en una secuencia de códigos discretos y el Transformer aprende sobre esos códigos junto con la información de posición y tipo de sensor. El uso de seis cuantizadores permite representar la señal mediante varios niveles discretos. La salida del modelo predice, para cada posición enmascarada, el código correspondiente en cada cuantizador.

4.3.4. Modelado temporal y espacial

La arquitectura final trabaja con segmentos largos de 150 segundos. Esta escala es mucho mayor que la utilizada por la mayoría de modelos EEG centrados en ventanas de pocos segundos. El objetivo es que las capas del Transformer aprendan tanto patrones locales como dependencias más amplias relacionadas con el estado de la grabación, la continuidad del estímulo y la dinámica temporal del procesamiento lingüístico.

La atención *criss-cross* separa explícitamente dos dimensiones. En la dimensión temporal, el modelo analiza cómo evoluciona la señal dentro de un sensor. En la dimensión espacial, integra información entre sensores manteniendo el mismo instante tokenizado. Esta separación reduce el coste respecto a una atención completa y se adapta de forma natural a la representación canal-tiempo del EEG.

En los registros *listeningcovert* de ds007808 se añade una restricción adicional mediante una máscara de objetivo. El contexto puede incluir toda la grabación, pero la pérdida solo se aplica sobre intervalos de escucha. Esto evita que el modelo sea entrenado para

reconstruir como objetivo principal periodos de habla encubierta, que no corresponden directamente a la percepción auditiva que se quiere transferir a ds004408.

4.4 Entrenamiento del modelo

4.4.1. Preentrenamiento autosupervisado

Cada entrenamiento ejecuta dos fases consecutivas:

1. entrenamiento continuo con datasets de lectura;
2. entrenamiento continuo con datasets de escucha, inicializado desde el mejor checkpoint de la fase de lectura correspondiente.

La fase de lectura utiliza Nieuwland et al. y ZuCo 2.0 en lectura natural. La fase de escucha utiliza SparrKULEE y OpenNeuro ds007808 (JapanEEG). La validación respeta separaciones por sujeto o por sesión según el dataset, como se describió en el capítulo anterior.

El orden de lectura → escucha se escogió para que los datasets de lectura proporcionen una primera adaptación a EEG lingüístico con estímulos visuales y condiciones relativamente controladas. Después, los datasets de escucha ajustan la representación al dominio auditivo continuo, que es el más próximo a la evaluación final con ds004408. El checkpoint producido por lectura se pasa explícitamente a la etapa de escucha, por lo que no se reutilizan checkpoints de experimentos anteriores de escucha aislada.

De esta forma el entrenamiento del modelo tiene la siguiente configuración: BioCodec, frecuencia final de 50 Hz, banda 0,1–40 Hz, ventanas de 150 segundos, batch size 4 en lectura y batch size 1 en escucha, validación cada 500 pasos y guardado periódico de checkpoints. El entrenamiento se ejecuta con una GPU por variante preentrenada, de forma que las condiciones pueden lanzarse en paralelo pero no comparten pesos entre sí.

En MEG-XL se realizó el entrenamiento con un batch size de 1. En la fase de lectura, el menor número de canales de EEG permite aumentar el lote a 4 sin superar la memoria de una GPU A100 de 40 GB. En la fase de escucha se mantiene batch size 1, porque los registros auditivos y la configuración de canales hacen que el coste de memoria sea mayor. Por tanto, la comparación entre condiciones no se basa en cambiar el tamaño de lote entre inicializaciones: todas las variantes preentrenadas utilizan batch size 4 en lectura y batch size 1 en escucha.

4.4.2. Clasificación contextual de palabras

El modelo de MEG-XL destaca por tener pocos parámetros entrenables para poder adaptarse a tareas supervisadas concretas. En este trabajo se mantiene la misma filosofía: el preentrenamiento autosupervisado aprende representaciones generales de EEG y la evaluación final se realiza mediante una tarea supervisada de clasificación contextual de palabras.

La clasificación contextual de palabras no forma parte del preentrenamiento autosupervisado continuo, sino que constituye la tarea supervisada utilizada para evaluar la calidad de las representaciones aprendidas. Una vez completadas las etapas de lectura y escucha, los checkpoints resultantes se emplean para inicializar el *fine-tuning* sobre OpenNeuro ds004408. Este conjunto se reserva para esta fase y no se incorpora al con-

junto de datos previo, evitando que el modelo haya observado previamente durante el preentrenamiento los registros utilizados en la evaluación final.

Las anotaciones temporales de ds004408 se obtienen de los niveles de palabras incluidos en los archivos *TextGrid*, descartando los niveles correspondientes a fonemas. Para cada palabra se extrae una ventana EEG de tres segundos, comprendida entre 0,5 segundos antes de su inicio y 2,5 segundos después. Posteriormente, se concatenan las ventanas correspondientes a 50 palabras consecutivas, produciendo una entrada de 150 segundos. Por tanto, la dimensión temporal coincide con la empleada durante el preentrenamiento, aunque en este caso no se trata necesariamente de 150 segundos continuos de la grabación original, sino de una secuencia estructurada de ventanas alineadas con palabras.

El modelo procesa conjuntamente las 50 ventanas y genera una representación para cada palabra. Sobre las características producidas por el Transformer se aplica una cabeza de proyección que transforma cada representación cerebral en un vector de 1024 dimensiones. Como objetivo lingüístico se utilizan embeddings extraídos de la capa intermedia 12 de *T5-large*. El aprendizaje se realiza mediante una pérdida contrastiva de tipo SigLIP, que aproxima la representación predicha al embedding de la palabra correcta y la separa de los embeddings correspondientes al resto de palabras presentes en el lote.

Durante la evaluación, cada embedding cerebral predicho se compara mediante similitud coseno con los embeddings lingüísticos de un conjunto de recuperación. Se consideran vocabularios formados por las 50 y las 250 palabras más frecuentes y se calcula la precisión *Top-10*, junto con su variante balanceada por palabra. Esta evaluación sigue la formulación de recuperación semántica utilizada en los trabajos de clasificación contextual de palabras, aunque los resultados solo pueden compararse directamente cuando coinciden el conjunto de candidatos, la partición de los datos y el protocolo de evaluación.




Figura 4.5: Ajuste y evaluación de palabras: ventanas alineadas, contexto EEG-XL, proyección cerebral, objetivo T5 y recuperación por ranking.

CAPÍTULO 5

Evaluación experimental

5.1 Diseño experimental

La evaluación de la arquitectura se ha diseñado separando tres efectos distintos: el aprendizaje autosupervisado con EEG, la transferencia de los pesos aprendidos previamente con MEG y la mejor forma de representar el tipo de sensor EEG dentro de la propia arquitectura. Para ello, primero se entrenan tres variantes del modelo mediante el mismo conjunto de lectura y escucha. A continuación, los checkpoints obtenidos se ajustan sobre OpenNeuro ds004408 para la tarea supervisada de clasificación contextual de palabras. Como referencia adicional se incluye una condición que realiza directamente el ajuste supervisado desde una inicialización aleatoria, sin preentrenamiento autosupervisado previo.

Los cuatro experimentos considerados en la evaluación final se resumen en la Tabla 5.1. Las tres variantes que siguen el currículo EEG utilizan exactamente los mismos datos, particiones, orden de las etapas e hiperparámetros. Las únicas diferencias entre ellas son la inicialización de los pesos y la fila de la tabla de embeddings utilizada para representar el tipo de sensor.

Condición	Inicialización del codificador	Representación del tipo de sensor	Conjunto EEG	Ajuste en ds004408
Sin preentrenamiento	Aleatoria	Embedding EEG inicializado aleatoriamente	No	Sí
Conjunto EEG desde cero	Aleatoria	Embedding específico de EEG	Lectura → escucha	Sí
Transferencia MEG-XL con embedding EEG	Checkpoint de MEG-XL	Embedding específico de EEG, inicializado a partir del embedding de magnetómetro	Lectura → escucha	Sí
Transferencia MEG-XL con embedding MEG	Checkpoint de MEG-XL	Embedding de magnetómetro reutilizado directamente	Lectura → escucha	Sí

Tabla 5.1: Condiciones incluidas en la evaluación experimental.

En el último experimento, denominado transferencia MEG-XL con embedding MEG, la señal continúa tratándose físicamente como EEG. Se mantienen las posiciones de los electrodos, la máscara de canales y la anulación de la contribución asociada a la orientación de las bobinas MEG. La única modificación consiste en utilizar, para los canales EEG,

la fila del embedding de tipo de sensor que MEG-XL había aprendido para los magnetómetros. Por tanto, esta condición permite estudiar de forma aislada si resulta beneficioso reutilizar directamente una representación de tipo de sensor ya entrenada.

La comparación entre las condiciones tiene las diferentes finalidades:

- La diferencia entre el modelo sin preentrenamiento y el conjunto EEG desde cero mide el efecto del preentrenamiento autosupervisado con los conjuntos de lectura y escucha.
- La comparación entre el conjunto EEG desde cero y la transferencia MEG-XL con embedding EEG permite estudiar la aportación de los pesos aprendidos originalmente con MEG.
- Finalmente, la comparación entre las dos variantes inicializadas desde MEG-XL permite analizar el efecto de utilizar un embedding específico de EEG o reutilizar directamente el embedding de magnetómetro.

5.2 Particiones de los datos

5.2.1. Preentrenamiento autosupervisado

El preentrenamiento se divide, como ya se ha explicado, en dos etapas consecutivas. La primera utiliza los conjuntos de lectura de Nieuwland et al. y ZuCo 2.0. La segunda continúa desde el mejor checkpoint de lectura de cada condición y utiliza SparrKULee y OpenNeuro ds007808. OpenNeuro ds004408 no participa en ninguna de estas dos etapas y se reserva por completo para el ajuste supervisado posterior.

Las particiones de validación varían entre por sujeto o por sesión, según la estructura de cada conjunto. Esto impide que fragmentos procedentes de una misma persona o de una misma sesión aparezcan simultáneamente en entrenamiento y validación. La Tabla 5.2 resume el criterio aplicado.

Etapas	Dataset	Criterio de partición	Validación
Lectura	Nieuwland et al.	Separación determinista por participante	10 % sujetos
Lectura	ZuCo 2.0	Separación determinista por participante	15 % sujetos
Escucha	SparrKULee	Participantes completos reservados	5 sujetos
Escucha	OpenNeuro ds007808	Sesiones completas reservadas	9 sesiones

Tabla 5.2: Particiones utilizadas durante las dos etapas del preentrenamiento autosupervisado.

En los registros *listeningcovert* de OpenNeuro ds007808 se conserva la grabación completa como contexto temporal. Sin embargo, únicamente los intervalos etiquetados como escucha pueden seleccionarse como objetivos de reconstrucción. De este modo, los periodos de habla encubierta mantienen la continuidad de la entrada, pero no contribuyen directamente a la pérdida de predicción de tokens.

5.2.2. Ajuste supervisado sobre OpenNeuro ds004408

Para el ajuste supervisado, cabe recordar que las anotaciones de palabras se obtienen a partir de los intervalos temporales asociados al nivel léxico. Cada ejemplo contiene 50 palabras consecutivas. Para cada palabra se extrae una ventana de tres segundos, desde

0,5 segundos antes de su inicio hasta 2,5 segundos después. Las 50 ventanas se agrupan para construir una entrada de 150 segundos, conservando así la misma longitud utilizada durante el preentrenamiento.

Todos los participantes escucharon los mismos estímulos. Por este motivo, una división aleatoria por ejemplos permitiría que una misma secuencia textual apareciese en más de una partición a través de participantes distintos. Para evitar esta fuga de información, la división se realiza agrupando por la secuencia completa de 50 palabras. Cada secuencia se asigna de forma determinista a entrenamiento, validación o test mediante una función hash con semilla fija. Todas las repeticiones de una misma secuencia quedan, por tanto, dentro de una única partición.

La proporción utilizada es 80 % para entrenamiento, 10 % para validación y 10 % para test. El conjunto de test no se emplea para seleccionar épocas, ajustar hiperparámetros ni aplicar parada temprana. La evaluación sobre test se realiza una sola vez después de recuperar el checkpoint con mejor resultado de validación.

5.3 Configuración del preentrenamiento

5.3.1. Representación de la entrada

Sea una ventana EEG $\mathbf{X} \in \mathbb{R}^{C \times T}$, donde C es el número máximo de canales representados y T el número de muestras temporales. Todas las señales se filtran inicialmente entre 0,1 y 40 Hz en su frecuencia de muestreo original y se remuestrean después a 50 Hz. Por la frecuencia de Nyquist final, la información efectivamente representable por el modelo queda limitada aproximadamente a 0,1–25 Hz. Por tanto, una ventana de 150 segundos contiene $T = 7500$ muestras por canal.

BioCodec se aplica de forma independiente sobre cada canal. El tokenizer produce una representación discreta

$$\mathbf{Z} \in \{0, \dots, V - 1\}^{C \times T' \times Q}, \quad (5.1)$$

donde $V = 256$ es el tamaño de cada vocabulario, $Q = 6$ es el número de cuantizadores residuales y T' es la dimensión temporal después de aplicar un factor de reducción $r = 12$. Los vectores de los seis niveles de cuantización se concatenan y se proyectan a una dimensión latente de 512.

La entrada al Transformer combina el contenido tokenizado con la posición del sensor y su tipo. Los sensores no disponibles en un montaje concreto se completan dentro de la dimensión común de canales, pero se identifican mediante una máscara. Esta representación permite compartir la arquitectura entre conjuntos adquiridos con diferente número y disposición de electrodos.

5.3.2. Objetivo autosupervisado

Cada ventana de 150 segundos se divide conceptualmente en 50 bloques de tres segundos. En cada ejemplo se seleccionan 20 bloques temporales no solapados para su enmascaramiento. El mismo intervalo temporal se oculta en todos los canales reales, lo que corresponde a una proporción nominal del 40 % de los bloques de la ventana.

Sea $\mathcal{M}$ el conjunto de posiciones canal-tiempo enmascaradas y $z_{c,t,q}$ el código objetivo del cuantizador q . El modelo genera una distribución $p_\theta(z_{c,t,q} \mid \mathbf{Z}_{\setminus \mathcal{M}})$ sobre los 256 códi-

gos posibles. La pérdida de predicción de tokens enmascarados es la entropía cruzada media sobre los seis cuantizadores:

$$\mathcal{L}_{\text{MTP}} = -\frac{1}{Q} \sum_{q=1}^Q \frac{1}{|\mathcal{M}|} \sum_{(c,t) \in \mathcal{M}} \log p_{\theta}(z_{c,t,q} \mid \mathbf{Z}_{\setminus \mathcal{M}}, \mathbf{P}, \mathbf{S}), \quad (5.2)$$

donde $\mathbf{P}$ representa la información espacial de los sensores y $\mathbf{S}$ incluye sus tipos y máscaras. Además de la pérdida, se registra la precisión media de predicción de los códigos y la precisión individual de cada cuantizador.

5.3.3. Hiperparámetros

Cada etapa puede ejecutarse durante un máximo de 50 épocas. La etapa de escucha se inicializa siempre desde el mejor checkpoint de validación obtenido por la misma condición en la etapa de lectura. No se transfieren pesos entre condiciones distintas.

Hiperparámetro	Valor
Frecuencia de muestreo	50 Hz
Banda inicial / banda efectiva	0,1–40 Hz / aprox. 0,1–25 Hz
Duración del contexto	150 s
Duración de cada bloque	3 s
Bloques enmascarados por ejemplo	20 de 50
Tokenizer	BioCodec
Cuantizadores / vocabulario	6 / 256 códigos
Factor de reducción temporal	12
Dimensión latente	512
Capas / cabezas de atención	8 / 8
Épocas máximas por etapa	50
Tamaño de lote en lectura	4
Tamaño de lote en escucha	1
Optimizador	AdamW
Tasa de aprendizaje	10^{-4}
Decaimiento de pesos	10^{-2}
Planificación de la tasa	Cosenoidal hasta 10^{-6}
Recorte de norma del gradiente	1,0
Precisión numérica	<i>bfloat16</i> mixta
Intervalo de validación	500 pasos
Semilla	42

Tabla 5.3: Configuración común del preentrenamiento autosupervisado.

Cada condición se ejecuta en una única GPU. Las condiciones pueden entrenarse en paralelo cuando existen dispositivos disponibles, pero cada una mantiene su propio optimizador, sus propios checkpoints y su propia trayectoria de entrenamiento.

5.4 Configuración del ajuste supervisado

5.4.1. Proyección al espacio lingüístico

Durante el ajuste supervisado no se utiliza la cabeza de reconstrucción de códigos del preentrenamiento. El Transformer produce características contextualizadas $\mathbf{H} \in \mathbb{R}^{C \times T' \times d}$, con $d = 512$. Para cada palabra i , se selecciona el intervalo temporal codificado correspondiente a su ventana y se calcula la media temporal de cada canal:

$$\bar{\mathbf{H}}_i = \frac{1}{|\mathcal{T}_i|} \sum_{t \in \mathcal{T}_i} \mathbf{H}_{:,t,:} \in \mathbb{R}^{C \times d}. \quad (5.3)$$

La matriz resultante se aplanan y se transforma mediante una cabeza de proyección de dos capas:

$$\hat{\mathbf{y}}_i = \mathbf{W}_2 \text{Dropout} \left(\text{GELU} \left(\text{LN} \left(\mathbf{W}_1 \text{vec}(\bar{\mathbf{H}}_i) + \mathbf{b}_1 \right) \right) \right) + \mathbf{b}_2, \quad (5.4)$$

donde la capa oculta tiene 2048 unidades y $\hat{\mathbf{y}}_i \in \mathbb{R}^{1024}$. El vector objetivo $\mathbf{y}_i$ se obtiene de la capa 12 de *T5-large*. Cuando una palabra se divide en varios tokens lingüísticos, sus representaciones se promedian para obtener un único embedding de 1024 dimensiones.

El tokenizer neuronal (BioCodec) permanece congelado. Se actualizan los pesos del codificador *criss-cross* y de la cabeza de proyección lingüística. La cabeza utilizada durante la predicción autosupervisada de códigos no interviene en esta etapa.

5.4.2. Pérdida contrastiva

El ajuste utiliza una pérdida contrastiva de tipo D-SigLIP. Sean $\hat{\mathbf{y}}_i$ las representaciones cerebrales predichas y $\mathbf{y}_j$ los embeddings lingüísticos objetivo del lote. La puntuación entre ambos vectores se define como

$$s_{ij} = \exp(\tau) \frac{\hat{\mathbf{y}}_i^\top \mathbf{y}_j}{\|\hat{\mathbf{y}}_i\|_2 \|\mathbf{y}_j\|_2} + b, \quad (5.5)$$

donde τ y b son parámetros aprendibles. La matriz de objetivos $a_{ij} \in \{0,1\}$ identifica las parejas positivas. Además de la pareja diagonal, se consideran positivas las palabras cuyos embeddings objetivo son prácticamente idénticos. La pérdida se calcula mediante entropía cruzada binaria sobre todas las parejas del lote:

$$\mathcal{L}_{\text{D-SigLIP}} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^N w_{ij} \left[a_{ij} \log \sigma(s_{ij}) + (1 - a_{ij}) \log (1 - \sigma(s_{ij})) \right], \quad (5.6)$$

donde w_{ij} evita contar varias veces candidatos duplicados y σ es la función sigmoide.

5.4.3. Hiperparámetros

Las condiciones preentrenadas utilizan una tasa de aprendizaje menor para el codificador y una tasa mayor para la nueva cabeza lingüística. La condición sin preentrenamiento utiliza la misma tasa para ambos componentes. El criterio principal de selección es la precisión Top-10 balanceada sobre el vocabulario de 250 palabras en validación.

Hiperparámetro	Valor
Tamaño de lote	1
Épocas máximas	50
Optimizador	AdamW
Decaimiento de pesos	10^{-4}
Tasa del modelo sin preentrenamiento	10^{-4}
Tasa del codificador preentrenado	10^{-5}
Tasa de la cabeza lingüística preentrenada	10^{-3}
Planificación de la tasa	Reducción por meseta, factor 0,5
Paciencia del planificador	5 épocas
Parada temprana	10 épocas
Mejora mínima	0,001
Recorte de norma del gradiente	1,0
Precisión numérica	<i>bfloat16</i> mixta
Vocabularios de recuperación	50 y 250 palabras
Número de candidatos aceptados	$k = 10$
Criterio de selección	Top-10 balanceada con 250 palabras
Semilla	42

Tabla 5.4: Configuración común del ajuste supervisado sobre OpenNeuro ds004408.

5.5 Métricas de evaluación

5.5.1. Métricas del preentrenamiento

El preentrenamiento se controla mediante la pérdida de reconstrucción de tokens y la precisión media de clasificación de los códigos enmascarados. Si $\hat{z}_{c,t,q}$ es el código de máxima probabilidad, la precisión se calcula como

$$\text{Acc}_{\text{token}} = \frac{1}{Q|\mathcal{M}|} \sum_{q=1}^Q \sum_{(c,t) \in \mathcal{M}} \mathbb{I} [\hat{z}_{c,t,q} = z_{c,t,q}]. \quad (5.7)$$

El checkpoint seleccionado en cada etapa es el que minimiza la pérdida de validación. Los resultados de lectura y escucha se presentan por separado porque la segunda etapa continúa desde la primera y utiliza conjuntos de datos diferentes.

5.5.2. Recuperación de palabras

Durante la evaluación supervisada, cada representación predicha se compara mediante similitud coseno con los embeddings de las M palabras más frecuentes. Solo se evalúan los ejemplos cuya etiqueta pertenece al vocabulario de recuperación $\mathcal{V}_M$. La precisión Top- k se define como

$$\text{Top-}k(M) = \frac{1}{N_M} \sum_{i: y_i \in \mathcal{V}_M} \mathbb{I} \left[y_i \in \text{TopK} \left(\{ \cos(\hat{y}_i, \mathbf{e}_w) \}_{w \in \mathcal{V}_M} \right) \right], \quad (5.8)$$

donde $\mathbf{e}_w$ es el embedding T5 de la palabra candidata y N_M es el número de ejemplos evaluados.

La frecuencia de las palabras no es uniforme. Por ello, la métrica principal es la precisión Top- k balanceada, que calcula primero la precisión de cada palabra y después realiza una media macro:

$$\text{BTop-}k(M) = \frac{1}{|\mathcal{V}_M|} \sum_{w \in \mathcal{V}_M} \frac{1}{N_w} \sum_{i: y_i = w} \mathbb{I}[w \in \text{TopK}_i]. \quad (5.9)$$

Se utiliza $k = 10$ con vocabularios de $M = 50$ y $M = 250$ palabras. Bajo una recuperación aleatoria uniforme, los niveles esperados son

$$P_{\text{azar}}(M, k) = \frac{k}{M}, \quad (5.10)$$

lo que corresponde al 20 % para 50 candidatos y al 4 % para 250 candidatos. Como métricas secundarias se registran la precisión Top-10 no balanceada, la similitud coseno media entre la predicción y el objetivo, el número de ejemplos evaluados y el número de ejemplos excluidos por no pertenecer al vocabulario de recuperación.

5.6 Resultados

En esta sección se presentan los resultados obtenidos en el preentrenamiento auto-supervisado y en el ajuste supervisado final sobre OpenNeuro ds004408. Las curvas de validación se utilizan únicamente para analizar la dinámica de entrenamiento y seleccionar el checkpoint de cada condición. La comparación principal entre modelos se realiza sobre la partición de test, evitando escoger el resultado final a partir de la misma partición utilizada para evaluar.

5.6.1. Preentrenamiento de lectura y escucha

La Figura 5.1 muestra la evolución de la precisión de predicción de códigos durante las dos etapas del currículo. En lectura, las dos condiciones inicializadas desde MEG-XL parten ya con una precisión de token superior a la del modelo EEG entrenado desde cero. Este último comienza más abajo y necesita varias épocas para aproximarse. Al final de la etapa la distancia se reduce, pero la inicialización desde MEG-XL sigue mostrando una pérdida de validación menor. En escucha, las tres condiciones continúan mejorando de forma gradual y las dos variantes transferidas desde MEG-XL se mantienen prácticamente solapadas.

La Tabla 5.5 recoge el mejor checkpoint de cada etapa según la pérdida global de validación. La precisión indicada corresponde a la media sobre los seis cuantizadores de BioCodec en ese mismo checkpoint.

Condición	Ép. lect.	Pérdida lect.	Acc. lect.	Ép. esc.	Pérdida esc.	Acc. esc.
Conjunto EEG desde cero	48	4,6988	4,96 %	30	4,5489	5,74 %
Transferencia MEG-XL con embedding EEG	47	4,6688	5,22 %	25	4,5340	5,74 %
Transferencia MEG-XL con embedding MEG	47	4,6688	5,22 %	25	4,5337	5,74 %

Tabla 5.5: Resultados de validación del preentrenamiento autosupervisado. El checkpoint se selecciona por mínima pérdida global de validación dentro de cada etapa.




Figura 5.1: Precisión de validación durante las dos etapas del preentrenamiento autosupervisado. La etapa de escucha continúa desde el checkpoint seleccionado tras la etapa de lectura para cada condición. Las barras de error, mostradas cada cinco épocas, indican una desviación típica entre los seis cuantizadores del tokenizador.

Estos resultados indican que la inicialización desde MEG-XL ayuda sobre todo al comienzo del currículo EEG. La mejora final de pérdida frente al modelo desde cero es pequeña, pero consistente en las dos etapas. La elección entre embedding EEG y embedding de magnetómetro apenas modifica el comportamiento autosupervisado: ambas variantes alcanzan valores prácticamente idénticos en lectura y diferencias inferiores a una milésima en la pérdida de escucha.

5.6.2. Clasificación contextual de palabras

La Figura 5.2 muestra la evolución de la métrica principal de validación durante el ajuste supervisado: Top-10 balanceada con vocabulario de 250 palabras. El control sin preentrenamiento se mantiene alrededor del azar, mientras que las tres condiciones preentrenadas superan ese nivel desde las primeras épocas. Además, la mejor validación aparece pronto, entre las épocas 3 y 5 según la condición. En particular, la mejor variante transferida desde MEG-XL selecciona el checkpoint de la época 3; a partir de ese punto la métrica de validación deja de mejorar e incluso tiende a descender aunque la pérdida de entrenamiento siga bajando. Por tanto, no parece que más épocas de ajuste añadan información útil para la tarea, sino que aumentan el riesgo de sobreajuste y de pérdida de generalización sobre ds004408.

La Tabla 5.6 presenta las métricas de test del checkpoint seleccionado para cada condición. La columna balanceada con 250 candidatos es la métrica principal, por ser la misma familia de métrica utilizada en la comparación con trabajos previos de clasificación de palabras.

La diferencia entre las métricas no balanceadas y balanceadas muestra por qué la métrica principal debe ser la macro-media por palabra. En el vocabulario de 250 palabras, el control sin preentrenamiento obtiene un 14,66 % de Top-10 no balanceada, pero solo un 4,05 % balanceado, prácticamente el 4 % esperado al azar. Esta discrepancia indica que la métrica no balanceada puede verse favorecida por palabras frecuentes. En cambio, las tres condiciones preentrenadas se mantienen claramente por encima del azar también en la métrica balanceada.

El modelo preentrenado con EEG desde cero alcanza un 19,95 % de Top-10 balanceada sobre 250 palabras. Por tanto, la mayor parte de la mejora procede de disponer de una fase de preentrenamiento autosupervisado antes del ajuste final. La transferencia desde




Figura 5.2: Precisión Top-10 balanceada con vocabulario de 250 palabras en la partición de validación de OpenNeuro ds004408. Esta es la métrica principal utilizada para seleccionar el checkpoint de cada condición.

Condición	Ép. sel.	Top-10, 50	Bal., 50	Top-10, 250	Bal., 250	Bal./azar
Sin preentrenamiento	3	27,77 %	20,00 %	14,66 %	4,05 %	1,01
Conjunto EEG desde cero	5	64,62 %	61,63 %	39,89 %	19,95 %	4,99
Transferencia MEG-XL con embedding EEG	4	63,62 %	62,50 %	40,98 %	20,56 %	5,14
Transferencia MEG-XL con embedding MEG	3	64,92 %	64,19 %	42,89 %	22,32 %	5,58
Azar uniforme	–	20,00 %	20,00 %	4,00 %	4,00 %	–

Tabla 5.6: Resultados de test del ajuste supervisado sobre OpenNeuro ds004408. Cada fila utiliza el checkpoint seleccionado mediante la mayor Top-10 balanceada sobre 250 palabras en validación.

MEG-XL añade una mejora adicional más moderada: la variante con embedding EEG alcanza un 20,56 %, mientras que la variante que reutiliza el embedding MEG obtiene el mejor resultado absoluto, con un 22,32 %.

5.6.3. Cobertura de la evaluación

La Tabla 5.7 muestra el número de ejemplos de test que entran en cada vocabulario de recuperación. Al ampliar el vocabulario de 50 a 250 palabras aumenta el número de ejemplos evaluados, pero también se reduce el nivel de azar de 20 % a 4 %, lo que hace más exigente la métrica.

Vocabulario	Ejemplos evaluados	Ejemplos excluidos	Cobertura
50 palabras	20 045	15 105	57,03 %
250 palabras	28 120	7 030	80,00 %

Tabla 5.7: Cobertura de los vocabularios de recuperación en la partición de test de ds004408. Los ejemplos excluidos corresponden a palabras fuera del vocabulario de recuperación considerado.

5.6.4. Diferencias entre condiciones

Para hacer explícitos los efectos definidos en el diseño experimental, la Tabla 5.8 presenta las diferencias absolutas entre condiciones sobre la partición de test. Estos valores son descriptivos, ya que cada condición se ha ejecutado con una única semilla.

Comparación	Δ bal., 50	Δ bal., 250
Efecto del preentrenamiento EEG: EEG desde cero menos sin preentrenamiento	+41,63 pp	+15,90 pp
Efecto de la transferencia MEG-XL: embedding EEG menos EEG desde cero	+0,87 pp	+0,61 pp
Efecto del embedding de sensor: embedding MEG menos embedding EEG	+1,69 pp	+1,76 pp

Tabla 5.8: Diferencias descriptivas entre las condiciones experimentales, expresadas en puntos porcentuales sobre la partición de test.

La diferencia dominante procede del preentrenamiento autosupervisado. El salto entre el modelo sin preentrenamiento y el modelo preentrenado con EEG desde cero es de 15,90 puntos porcentuales en la métrica principal. La transferencia desde MEG-XL aporta una mejora adicional de 0,61 puntos cuando se utiliza el embedding EEG. En esta ejecución, la reutilización directa del embedding de magnetómetro obtiene el mejor valor absoluto, 22,32 %, y supera al embedding EEG específico por 1,76 puntos. Esta última diferencia debe interpretarse con prudencia: al disponer de una única semilla, no permite concluir superioridad estadística de una representación de sensor sobre la otra.

5.6.5. Comparación con trabajos previos

La comparación más directa es con d'Ascoli et al. [11], porque utilizan una formulación de evaluación equivalente: recuperación Top-10 balanceada sobre las 250 palabras más frecuentes y descarte de palabras fuera del vocabulario. En Broderick/OpenNeuro ds004408, d'Ascoli et al. reportan aproximadamente un 20 % de precisión Top-10 balanceada en la Figura 2C. Bajo la misma métrica, el mejor modelo de este trabajo alcanza

un 22,32 % sobre test, lo que supone una mejora descriptiva de 2,32 puntos porcentuales respecto a esa referencia aproximada.

Sin embargo, esta comparación no debe limitarse al valor final de precisión. d’Ascoli et al. entrenan un modelo supervisado de alta capacidad; MEG-XL lo utiliza como referencia de estado del arte supervisado y lo describe como un modelo de aproximadamente 200 millones de parámetros, frente a los 20 millones del codificador MEG-XL original [30]. En esta adaptación a EEG, la comparación de parámetros debe matizarse: la cabeza lingüística usada para ds004408 aplanar los 128 canales codificados y proyecta el vector resultante mediante una capa oculta de 2048 unidades. Solo esa cabeza contiene

$$(128 \cdot 512) \cdot 2048 + 2048 + 2 \cdot 2048 + 2048 \cdot 1024 + 1024 = 136\,322\,048 \quad (5.11)$$

parámetros entrenables, sin contar el codificador criss-cross ni el tokenizer congelado. Por tanto, el resultado no debe presentarse como una mejora obtenida con un modelo diminuto, sino como una adaptación competitiva que reutiliza un codificador preentrenado y concentra gran parte de la capacidad adicional en una cabeza supervisada específica para la tarea.

La diferencia más relevante respecto a d’Ascoli et al. está en la eficiencia del ajuste. MEG-XL muestra que el preentrenamiento puede sustituir parcialmente a datos supervisados específicos del sujeto: supera a d’Ascoli et al. en regímenes de pocos datos y solo pierde ventaja cuando existen grabaciones profundas de un mismo sujeto [30]. En este trabajo no se ha realizado todavía un barrido reduciendo el porcentaje de entrenamiento de ds004408, por lo que no puede afirmarse de forma estricta que EEG-XL necesite menos horas de datos supervisados. Lo que sí muestran las curvas de validación es que el mejor checkpoint aparece muy pronto: la condición con mejor test selecciona la época 3, y continuar el ajuste no mejora la métrica principal. Esta dinámica es coherente con la idea de que el preentrenamiento proporciona una representación inicial útil y que, en EEG, el ajuste supervisado prolongado puede degradar la generalización antes que mejorarla.

También puede compararse con Jayalath et al. [28], aunque con más cautela porque emplean una partición diferente de Broderick y porque su trabajo combina clasificación de palabras con reconstrucción contextual de texto. Sus métricas de reconstrucción completa, como WER, CER, BLEU o ROUGE, no son directamente comparables con la recuperación cerrada de palabras usada en este capítulo. La comparación relevante está en sus experimentos de clasificación de palabras sobre Broderick: el entrenamiento solo con Broderick aparece alrededor del nivel de azar y la combinación con LibriBrain alcanza aproximadamente un 7 %. Frente a esos valores, el 22,32 % obtenido aquí sitúa la adaptación de MEG-XL a EEG claramente por encima del azar y en el mismo orden de magnitud que los mejores resultados publicados para este conjunto.

Aun así, la comparación debe interpretarse con prudencia. Las particiones no son idénticas entre trabajos, las implementaciones difieren en el preprocesamiento y este experimento se ha ejecutado con una única semilla. Por tanto, el resultado no demuestra una superioridad definitiva sobre d’Ascoli et al., pero sí muestra un comportamiento relevante para este TFM: una arquitectura transferida desde MEG alcanza un resultado competitivo en EEG y lo hace con una ventana de ajuste muy corta, antes de que el entrenamiento supervisado empiece a deteriorar la validación.

5.6.6. Resumen de los resultados

Los resultados obtenidos permiten extraer cinco conclusiones principales. Primero, el ajuste supervisado desde una inicialización aleatoria no aprende una representación

balanceada útil para recuperar palabras y se mantiene en el nivel de azar con 250 candidatos. Segundo, el preentrenamiento autosupervisado con EEG produce la mayor mejora, elevando la Top-10 balanceada sobre 250 palabras de 4,05 % a 19,95 %. Tercero, la inicialización desde MEG-XL mejora de nuevo el resultado, aunque con una ganancia menor que la aportada por el propio preentrenamiento EEG. Cuarto, en esta ejecución la reutilización del embedding de magnetómetro obtiene el mejor resultado final, con un 22,32 % de Top-10 balanceada sobre 250 palabras. Quinto, la comparación con d'Ascoli et al. debe interpretarse también desde la eficiencia de adaptación: el mejor resultado de EEG-XL aparece en la época 3 y continuar el ajuste supervisado no mejora la validación, lo que sugiere que el modelo aprovecha pronto las representaciones transferidas pero se sobreajusta con facilidad.

En conjunto, estos experimentos muestran que la adaptación de una arquitectura de contexto largo inspirada en MEG-XL a EEG es viable para clasificación contextual de palabras. El resultado principal sitúa el sistema claramente por encima del azar y en el rango de los mejores resultados publicados sobre Broderick/OpenNeuro ds004408, aunque queda pendiente confirmar la tendencia con más semillas y con un protocolo exactamente alineado con los trabajos comparados.

CAPÍTULO 6

Conclusiones y trabajo futuro

6.1 Conclusiones

6.2 Cumplimiento de los objetivos

6.3 Líneas de trabajo futuro

- Diferentes bandas de frecuencia comprobando frecuencia de Nyquist
- Diferentes tokenizadores
- Entrenar con Brain2Qwerty
- Espacio de embeddings para cada zona del cerebro (temporal, frontal, parietal, occipital)
- Crear dataset propio de EEG de escucha continua en español
- Hacer pruebas con cascos reales de estos modelos
- Añadir más conjuntos de datos al conjunto de preentrenamiento actual debido a la cantidad de ruido que tiene la señal de EEG

Bibliografía

- [1] Bernd Accou, Lies Bollens, Marlies Gillis, Wendy Verheijen, Hugo Van hamme, and Tom Francart. SparrKULee: A speech-evoked auditory response repository from KU Leuven, containing the EEG of 85 participants. *Data*, 9(8):94, 2024.
- [2] Salwa Alzahrani, Haneen Banjar, and Rsha Mirza. Systematic review of EEG-based imagined speech classification methods. *Sensors*, 24(24):8168, 2024.
- [3] Kristijan Armeni, Umut Güçlü, Marcel A. J. van Gerven, and Jan-Mathijs Schoffelen. A 10-hour within-participant magnetoencephalography narrative dataset to test models of language comprehension. *Scientific Data*, 9:278, 2022.
- [4] Konstantinos Avramidis, Tiantian Feng, Won Jeong, Joon Lee, Weizhong Cui, Richard M. Leahy, and Shrikanth Narayanan. Neural codecs as biosignal tokenizers, 2025.
- [5] Alexei Baevski, Yuhao Zhou, Abdelrahman Mohamed, and Michael Auli. wav2vec 2.0: A framework for self-supervised learning of speech representations. In *Advances in Neural Information Processing Systems*, volume 33, pages 12449–12460, 2020.
- [6] Elena Boto, Niall Holmes, James Leggett, Gillian Roberts, Vishal Shah, Sofie S. Meyer, Leonardo Duque Muñoz, Karen J. Mullinger, Tim M. Tierney, Sven Bestmann, Gareth R. Barnes, Richard Bowtell, and Matthew J. Brookes. Moving magnetoencephalography towards real-world applications with a wearable system. *Nature*, 555(7698):657–661, 2018.
- [7] Michael P. Broderick, Andrew J. Anderson, Giovanni M. Di Liberto, Michael J. Crosse, and Edmund C. Lalor. Electrophysiological correlates of semantic dissimilarity reflect the comprehension of natural, narrative speech. *Current Biology*, 28(5):803–809, 2018.
- [8] Kay H. Brodersen, Cheng Soon Ong, Klaas E. Stephan, and Joachim M. Buhmann. The balanced accuracy and its posterior distribution. In *2010 20th International Conference on Pattern Recognition*, pages 3121–3124, 2010.
- [9] György Buzsáki and Andreas Draguhn. Neuronal oscillations in cortical networks. *Science*, 304(5679):1926–1929, 2004.
- [10] Stéphane d’Ascoli, Corentin Bel, Jérémy Rapin, Hubert Banville, Yohann Benchetrit, Christophe Pallier, Jean-Rémi King, et al. Towards decoding individual words from non-invasive brain recordings. *Nature Communications*, 16:10521, 2025.
- [11] Stéphane d’Ascoli, Corentin Bel, Jérémy Rapin, Hubert J. Banville, Yohann Benchetrit, Christophe Pallier, and Jean-Rémi King. Towards decoding individual words from non-invasive brain recordings. *Nature Communications*, 16:10521, 2025. Preprint originally released as arXiv:2412.17829.

- [12] Debadatta Dash, Paul Ferrari, and Jun Wang. Decoding imagined and spoken phrases from non-invasive neural (MEG) signals. *Frontiers in Neuroscience*, 14:290, 2020.
- [13] Alexandre Défossez, Charlotte Caucheteux, Jérémy Rapin, Ori Kabeli, and Jean-Rémi King. Decoding speech perception from non-invasive brain recordings. *Nature Machine Intelligence*, 5:1097–1107, 2023.
- [14] Arnaud Delorme and Scott Makeig. EEGLAB: An open source toolbox for analysis of single-trial EEG dynamics including independent component analysis. *Journal of Neuroscience Methods*, 134(1):9–21, 2004.
- [15] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of NAACL-HLT*, pages 4171–4186, 2019.
- [16] Giovanni M. Di Liberto, James A. O’Sullivan, and Edmund C. Lalor. Low-frequency cortical entrainment to speech reflects phoneme-level processing. *Current Biology*, 25(19):2457–2465, 2015.
- [17] Olaf Dimigen, Werner Sommer, Annette Hohlfeld, Arthur M. Jacobs, and Reinhold Kliegl. Coregistration of eye movements and EEG in natural reading: Analyses and review. *Journal of Experimental Psychology: General*, 140(4):552–572, 2011.
- [18] Yiqun Duan, Jinzhao Zhou, Zhen Wang, Yu-Kai Wang, and Chin-Teng Lin. DeWave: Discrete encoding of EEG waves for EEG-to-text translation. In *Advances in Neural Information Processing Systems*, volume 36, pages 9907–9918, 2023.
- [19] Bradley J. Edelman, Shuailei Zhang, Gerwin Schalk, Peter Brunner, Gernot Müller-Putz, Cuntai Guan, and Bin He. Non-invasive brain-computer interfaces: State of the art and trends. *IEEE Reviews in Biomedical Engineering*, 18:26–49, 2025.
- [20] Andreas K. Engel and Pascal Fries. Beta-band oscillations—signalling the status quo? *Current Opinion in Neurobiology*, 20(2):156–165, 2010.
- [21] Alexandre Gramfort, Martin Luessi, Eric Larson, et al. MEG and EEG data analysis with MNE-Python. *Frontiers in Neuroscience*, 7:267, 2013.
- [22] Joachim Gross, Sylvain Baillet, Gareth R. Barnes, Richard N. Henson, Arjan Hillebrand, Ole Jensen, Karim Jerbi, Vladimir Litvak, Burkhard Maess, Robert Oostenveld, Lauri Parkkonen, Jason R. Taylor, Virginie van Wassenhove, Michael Wibral, and Jan-Mathijs Schoffelen. Good practice for conducting and reporting MEG research. *NeuroImage*, 65:349–363, 2013.
- [23] Laura Gwilliams, Graham Flick, Alec Marantz, Liina Pylkkänen, David Poeppel, and Jean-Rémi King. Introducing MEG-MASC: A high-quality magnetoencephalography dataset for evaluating natural speech processing. *Scientific Data*, 10:862, 2023.
- [24] Matti S. Hämäläinen, Riitta Hari, Risto J. Ilmoniemi, Jukka Knuutila, and Olli V. Lounasmaa. Magnetoencephalography—theory, instrumentation, and applications to noninvasive studies of the working human brain. *Reviews of Modern Physics*, 65(2):413–497, 1993.
- [25] Kenneth D. Harris. Nonsense correlations in neuroscience. *bioRxiv*, 2021. Preprint.

- [26] Nora Hollenstein, Marius Troendle, Ce Zhang, and Nicolas Langer. ZuCo 2.0: A dataset of physiological recordings during natural reading and annotation. In *Proceedings of the Twelfth Language Resources and Evaluation Conference*, pages 138–146, Marseille, France, 2020. European Language Resources Association.
- [27] Herbert H. Jasper. The ten-twenty electrode system of the international federation. *Electroencephalography and Clinical Neurophysiology*, 10:371–375, 1958.
- [28] Dulhan Jayalath, Gilad Landau, and Oiwi Parker Jones. Unlocking non-invasive brain-to-text, 2025.
- [29] Dulhan Jayalath, Gilad Landau, Brendan Shillingford, Mark Woolrich, and Oiwi Parker Jones. The brain’s bitter lesson: Scaling speech decoding with self-supervised learning. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pages 27005–27020. PMLR, 2025.
- [30] Dulhan Jayalath and Oiwi Parker Jones. MEG-XL: Data-efficient brain-to-text via long-context pre-training, 2026.
- [31] Weibang Jiang, Liming Zhao, and Bao-Liang Lu. Large brain model for learning generic representations with tremendous EEG data in BCI. In *The Twelfth International Conference on Learning Representations*, 2024.
- [32] Hyejeong Jo, Yiqian Yang, Juhyeok Han, Yiqun Duan, Hui Xiong, and Won Hee Lee. Are EEG-to-text models working?, 2024.
- [33] Wolfgang Klimesch. EEG alpha and theta oscillations reflect cognitive and memory performance: A review and analysis. *Brain Research Reviews*, 29(2–3):169–195, 1999.
- [34] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- [35] Jarod Lévy, Mingfang Zhang, Svetlana Pinet, Jérémy Rapin, Hubert Banville, Stéphane d’Ascoli, Jean-Rémi King, et al. Noninvasive decoding of typed sentences from human brain activity. *Nature Neuroscience*, 2026.
- [36] David A. Moses, Sean L. Metzger, Jessie R. Liu, et al. Neuroprosthesis for decoding speech in a paralyzed person with anarthria. *New England Journal of Medicine*, 385:217–227, 2021.
- [37] Elon Musk and Neuralink. An integrated brain-machine interface platform with thousands of channels. *Journal of Medical Internet Research*, 21(10):e16194, 2019.
- [38] Mante S. Nieuwland et al. Large-scale replication study reveals a limit on probabilistic prediction in language comprehension. *eLife*, 7:e33468, 2018.
- [39] Robert Oostenveld and Peter Praamstra. The five percent electrode system for high-resolution EEG and ERP measurements. *Clinical Neurophysiology*, 112(4):713–719, 2001.
- [40] Miran Özdogan, Gilad Landau, Gereon Elvers, Dulhan Jayalath, Pratik Somaiya, Francesco Mantegna, Mark Woolrich, and Oiwi Parker Jones. LibriBrain: Over 50 hours of within-subject MEG to improve speech decoding methods at scale. In *Advances in Neural Information Processing Systems: Datasets and Benchmarks Track*, 2025.
- [41] Sinno Jialin Pan and Qiang Yang. A survey on transfer learning. *IEEE Transactions on Knowledge and Data Engineering*, 22(10):1345–1359, 2010.

- [42] Jerrin Thomas Panachakel and Angarai Ganesan Ramakrishnan. Decoding covert speech from EEG—a comprehensive review. *Frontiers in Neuroscience*, 15:642251, 2021.
- [43] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of Machine Learning Research*, 21(140):1–67, 2020.
- [44] Yannick Roy, Hubert Banville, Isabela Albuquerque, Alexandre Gramfort, Tiago H. Falk, and Jocelyn Faubert. Deep learning-based electroencephalography analysis: A systematic review. *Journal of Neural Engineering*, 16(5):051001, 2019.
- [45] Luis Carlos Sarmiento, Sergio Villamizar, Omar López, Ana Claros Collazos, Jhon Sarmiento, and Jan Bacca Rodríguez. Recognition of EEG signals from imagined vowels using deep learning methods. *Sensors*, 21(19):6503, 2021.
- [46] Motoshige Sato, Ilya Horiguchi, Masakazu Inoue, Kenichi Tomeoka, Eri Hatakeyama, Yuya Kita, Atsushi Yamamoto, Ippei Fujisawa, and Shuntaro Sasai. A 1000-hour EEG–EMG–Audio dataset of japanese speech production, 2026. Dataset OpenNeuro ds007808.
- [47] Motoshige Sato, Kenichi Tomeoka, Ilya Horiguchi, Kai Arulkumaran, Ryota Kanai, and Shuntaro Sasai. Scaling law in neural data: Non-invasive speech decoding with 175 hours of EEG data, 2024.
- [48] Andrew B. Silva, Kirsten T. Littlejohn, Jessie R. Liu, David A. Moses, and Edward F. Chang. The speech neuroprosthesis. *Nature Reviews Neuroscience*, 25:473–492, 2024.
- [49] Markus-Oliver Tamm, Yar Muhammad, and Naveed Muhammad. Classification of vowels from imagined speech with convolutional neural networks. *Computers*, 9(2):46, 2020.
- [50] Samu Taulu and Matti Kajola. Presentation of electromagnetic multichannel data: The signal space separation method. *Journal of Applied Physics*, 97(12):124905, 2005.
- [51] A.^aron van den Oord, Oriol Vinyals, and Koray Kavukcuoglu. Neural discrete representation learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [52] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [53] Guangyu Wang, Wenchao Liu, Yuhong He, Cong Xu, Lin Ma, and Haifeng Li. EEGPT: Pretrained transformer for universal and reliable representation of EEG signals. In *Advances in Neural Information Processing Systems*, volume 37, pages 39249–39280, 2024.
- [54] Jiquan Wang, Sha Zhao, Zhiling Luo, Yangxuan Zhou, Haiteng Jiang, Shijian Li, Tao Li, and Gang Pan. CBraMod: A criss-cross brain foundation model for EEG decoding. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [55] Zhenhailong Wang and Heng Ji. Open vocabulary electroencephalography-to-text decoding and zero-shot sentiment classification. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 36, pages 5350–5358, 2022.

- [56] Andreas Widmann, Erich Schröger, and Burkhard Maess. Digital filter design for electrophysiological data—a practical approach. *Journal of Neuroscience Methods*, 250:34–46, 2015.
- [57] Francis R. Willett, Erin M. Kunz, Chaofei Fan, et al. A high-performance speech neuroprosthesis. *Nature*, 620:1031–1036, 2023.
- [58] Jonathan R. Wolpaw, Niels Birbaumer, Dennis J. McFarland, Gert Pfurtscheller, and Theresa M. Vaughan. Brain-computer interfaces for communication and control. *Clinical Neurophysiology*, 113(6):767–791, 2002.
- [59] Qinfan Xiao, Ziyun Cui, Chi Zhang, Siqi Chen, Wen Wu, Andrew Thwaites, Alexandra Woolgar, Bowen Zhou, and Chao Zhang. BrainOmni: A brain foundation model for unified EEG and MEG signals. In *Advances in Neural Information Processing Systems*, 2025.
- [60] Dezhong Yao, Yuchen Qin, Sheng Hu, Liang Dong, Maria L. Bringas Vega, and Pedro A. Valdés Sosa. Which reference should we use for EEG and ERP practice? *Brain Topography*, 32(4):530–549, 2019.
- [61] Thorsten O. Zander and Christian Kothe. Towards passive brain–computer interfaces: Applying brain–computer interface technology to human–machine systems in general. *Journal of Neural Engineering*, 8(2):025005, 2011.
- [62] Neil Zeghidour, Alejandro Luebs, Ahmed Omran, Jan Skoglund, and Marco Tagliasacchi. Soundstream: An end-to-end neural audio codec. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, 30:495–507, 2022.
- [63] Xiaohua Zhai, Basil Mustafa, Alexander Kolesnikov, and Lucas Beyer. Sigmoid loss for language image pre-training. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 11975–11986, 2023.
- [64] Chiyuan Zhang, Samy Bengio, Moritz Hardt, Benjamin Recht, and Oriol Vinyals. Understanding deep learning requires rethinking generalization. In *International Conference on Learning Representations*, 2017.

APÉNDICE A

Configuració del sistema

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.1 Fase d'inicialització

???? ????????????? ????????????? ????????????? ????????????? ?????????????

A.2 Identificació de dispositius

???? ????????????? ????????????? ????????????? ????????????? ?????????????

APÉNDICE B

??? ?????????????? ????

???? ?????????????? ?????????????? ?????????????? ?????????????? ??????????????