

Transferencia de modelos MEG de contexto largo a EEG

Clasificación de palabras en escucha natural

Ricardo Díaz Peris

Tutores: Vicent Juan Botti Navarro, Alfons Juan Císcar

MIARFID - UPV



- 1 Motivación y contexto
- 2 Hipótesis y propuesta
- 3 Datos y metodología
- 4 Resultados
- 5 Conclusiones

¿Cómo de difícil es leer la mente? (Decodificación de lenguaje)

Objetivo a largo plazo

señales cerebrales → lenguaje →
comunicación

Por qué sigue siendo difícil

- Señal cerebral no invasiva indirecta, ruidosa y variable.
- Cada palabra contexto temporal y lingüístico.
- Los datos cerebro–texto alineados son escasos y caros.
- Generalización sujetos, sesiones y datasets limitada.

BCI

interfaz cerebro–ordenador

B2T

brain-to-text

reto

pasar de señales ruidosas a palabras

Invasivo vs. no invasivo



ECoG




EEG



MEG



fMRI



BCI con EEG en videojuegos


Comparativa de métodos no invasivos

Método	Temporal	Espacial	Coste	Encaje en decodificación de lenguaje
EEG	Alta	Baja	Bajo	BCI portable; ruidoso para texto natural
MEG	Alta	Media	Alto	Aprender representación temporal lenguaje
fMRI	Baja	Alta	Alto	Útil semántica; no nivel palabra tiempo real

Hipótesis del TFM


MEG permite aprender representaciones de mayor calidad, ¿arquitectura de contexto largo entrenada con MEG punto de partida para EEG?.

MEG vs EEG



Potenciales eléctricos
difusos en el cuero cabelludo

Misma actividad
neural subyacente



Campos magnéticos
medidos por sensores externos

Leyenda

- cabeza/cuero cabelludo
- cerebro
- fuente neuronal
- proyección eléctrica
- electrodos EEG
- sensores MEG
- casco/sensores externos
- ➔ campo magnético

Qué capta realmente un casco de EEG



Lo que mide

Diferencias potencial cuero cabelludo, generadas por actividad neuronal sincronizada observada por electrodos.



Lo que también capta

Parpadeos, movimiento ocular, tensión muscular, mala impedancia, movimiento del casco y ruido eléctrico.

Resumen

Registra señales microvoltios con mucho ruido. Por eso hacen falta preprocesamiento, contexto largo y preentrenamiento.

Momento casco



Punto de partida

MEG-XL: modelo autosupervisado de contexto largo para señales MEG.

Adaptación

EEG-XL: entrada EEG con posiciones, máscaras y tipo de sensor.

Evaluación

Recuperación Top-10 de palabras sobre OpenNeuro ds004408.

¿Puede un modelo MEG de contexto largo adaptarse a EEG para clasificación contextual de palabras?


Propuesta: de MEG-XL a EEG-XL

Idea central

Modelo pocos parámetros capaz de entender MEG y especializar con pocos datos.

Cambio necesario

Representar EEG heterogéneo: distinto número de canales, distintas posiciones y distintas sesiones.



Lectura


- ZuCo 2.0: 11,1 h NR; lectura natural.
- Nieuwland et al.: ~170 h; lectura palabra a palabra.
- Adaptación inicial a EEG lingüístico.

Escucha

- SparrKULee: 168 h; habla natural.
- OpenNeuro ds007808: 33,8 h escucha + 167 h contexto.
- Aproxima el dominio de evaluación.

Evaluación final

- OpenNeuro ds004408: 20,6 h.
- Reservado para fine-tuning y test.
- No participa en el preentrenamiento.



Objetivo

Convertir datasets EEG heterogéneos en entradas compatibles con una arquitectura común.

Importante


Nyquist fija la frecuencia máxima tras el remuestreo:

$$f_N = f_s / 2 = 50 / 2 = 25 \text{ Hz}$$


Aunque el filtro llegue a 40 Hz, el modelo usa aprox. 0,1–25 Hz.

frecuencia EEG
oscilaciones de la señal
0,1–40 Hz


frecuencia de muestreo
muestras por segundo
50 Hz




Preentrenamiento autosupervisado



150 s
contexto



50
bloques



20/50
máscara


Fuente: MEG-XL

Construcción del ejemplo

- Cada palabra tiene un tiempo de inicio.
- Se extrae una ventana EEG de 3 s.
- 50 palabras forman una entrada de 150 s.

Objetivo lingüístico

La representación cerebral se proyecta al espacio de embeddings de *T5-large*.



Diseño experimental: separar efectos

Modelo	Inicialización	Preentrenamiento EEG	Fine-tuning
Sin preentrenamiento	Aleatoria	No	ds004408
EEG desde cero	Aleatoria	Lectura → escucha	ds004408
MEG-XL + emb. EEG	Checkpoint MEG-XL	Lectura → escucha	ds004408
MEG-XL + emb. MEG	Checkpoint MEG-XL	Lectura → escucha	ds004408

Qué permite medir

- Efecto del preentrenamiento autosupervisado con EEG.
- Efecto de inicializar desde MEG-XL.
- Efecto de reutilizar o redefinir el embedding de tipo de sensor.

Resultado principal

Métrica principal

Top-10 balanceada sobre las 250 palabras más frecuentes de ds004408.

22,32 %

mejor modelo: MEG-XL + embedding MEG

~20 %

estado del arte comparable en ds004408


4,00 %

azar uniforme con 250 candidatos

Condición	Bal. 250	Bal./azar
Sin preentrenamiento	4,05 %	1,01
EEG desde cero	19,95 %	4,99
MEG-XL + emb. EEG	20,56 %	5,14
MEG-XL + emb. MEG	22,32 %	5,58

Lectura principal

Se supera la referencia aproximada de d'Ascoli et al. (~20 %) en la misma métrica: +2,32 pp. La comparación es descriptiva.



Observación

Los mejores checkpoints aparecen en pocas épocas.

Riesgo

Continuar el fine-tuning no mejora necesariamente y puede degradar la generalización.

Interpretación

El preentrenamiento proporciona una representación útil, pero el EEG se sobreajusta con facilidad.

Viabilidad

- Arquitectura puede adaptarse a EEG.
- Sistema supera el azar.
- Contexto largo compatible también con EEG.

Qué aporta más

- Mayor salto viene del preentrenamiento EEG.
- MEG-XL aporta una mejora adicional moderada.
- Embedding MEG reutilizado mejor en esta ejecución.

Cuidado

- Una única semilla.
- Perdemos info por Nyquist.
- No generación libre de texto.

Lectura: la transferencia MEG-EEG no resuelve el brain-to-text no invasivo, pero muestra una vía viable y medible para avanzar.

Qué se ha conseguido

- Adaptar MEG-XL a EEG heterogéneo.
- Entrenar con lectura y escucha.
- Evaluar recuperación de palabras en ds004408.

Resultado central

- 22,32 % Top-10 balanceada.
- Supera estado arte menos parámetros.
- El preentrenamiento EEG es decisivo.

Trabajo futuro

- Más semillas y particiones.
- Posible paper si confirma mejora sobre el estado arte.
- Más bandas, remuestreos, tokenizadores y datasets.
- Separar embeddings por zonas del cerebro.
- Agregar LLMs para generación libre de texto.
- Probar modelo con registros propios con casco EEG.

Gracias

Preguntas, recomendaciones,
incordios

